

基于PCA混合模型的多模态过程监测

Xianzhen Xu, Lei Xie, Shuqing Wang

Computers and Electrical Engineering, Vol. 40, 2014, pp. 2101–2112

摘要:

对于多模态过程，高斯混合模型（GMM）近年来已被应用于估计正常运行条件下过程数据的概率密度函数。然而，对于高维且具有共线性的过程变量，使用期望最大化（EM）算法从过程数据中学习GMM可能很困难甚至不可行。为解决这一问题，本文提出了一种基于PCA混合模型的新型多模态过程监测方法。首先，将PCA技术直接应用于每个高斯分量的协方差矩阵，以降低过程变量维度并获得非奇异协方差矩阵。然后，采用贝叶斯阴阳增量EM算法自动优化混合分量数量。利用获得的PCA混合模型，推导出一种新的过程监测方案用于多模态过程的故障检测。提供了三个案例研究来评估所提方法的监测性能。

关键词：多模态过程监测，故障检测，高斯混合模型，EM算法，PCA，田纳西伊斯曼过程

1. 引言

随着现代工业过程对过程安全和产品质量要求的不断提高，监测和故障诊断变得越来越重要[1]。在过去的几十年里，多元统计过程监测（MSPM）方法，如主成分分析（PCA）和偏最小二乘（PLS），已在不同工业过程中被广泛应用于过程分析和监测[2–4]。传统的MSPM方法依赖于操作数据服从单模态高斯分布的假设。然而，在现代工业过程中，由于进料流量、产品规格、设定点等的变化，经常遇到操作模式变化的情况[5]，传统的多元过程监测技术不适合此类情况。

本文聚焦于多模态过程特性的统计监测。多模态过程的实时监测是一个具有挑战性的问题，近年来引起了越来越多的关注。过去几年中已经开发了一些多模态过程监测方法，包括全局PCA模型[5]、自适应方法[6, 7]、多模型方法[3, 8]、基于高斯混合模型的方法[9, 10]、外部分析[11, 12]等。全局PCA模型仅在不同操作模式共享共同协方差结构时才适用，这限制了其在许多情况下的应用。自适应方法是盲目实施的，容易导致误报警，特别是在两个操作模式的过渡期间。基于多模型的方法也可能出现类似问题，因为它们需要将监测数据样本分配给单一监测模型。对于基于外部分析的方法，没有适当的过程知识就难以执行。

有限混合模型是一种灵活的多元数据概率方法。高斯混合模型（GMM）最近已被应用于多模态过程监测[9, 10, 13]，其中每个高斯分量对应一个独立的操作模式。通常，高斯混合的参数可以在最大似然框架下通过期望最大化（EM）算法来估计[14–17]。然而，EM有以下局限性：（i）它假设混合中高斯分量的数量是先验已知且固定的；（ii）它是一种局部搜索方法，不恰当的初始化可能使其陷入局部最大值；（iii）变量之间的共线性导致协方差矩阵奇异，产生病态问题，无法通过朴素EM算法求解。

对于局限性（i）和（ii），鉴于缺乏先验过程知识，混合分量的数量是未知的。最近，一些通过选择准则（如贝叶斯推断准则、最小描述长度等）解决此问题的新方法被提出。这些方法可分为两类：（i）剪枝算法，从任意大的分量数量开始，通过消除不显著权重的分量来自适应调整数量，如F-J算法[18]；（ii）增量算法，从一两个分量开始，在每次EM程序后顺序添加新分量，直到达到最大分量数。理论证据[14]表明，通过增量地向混合中添加分量到所需数量，可以最大似然地学习混合密度。基于近似结果，Vlassis[15]提出了一种贪婪EM算法，该算法在[16]中被进一步讨论和加强。然而，贪婪EM算法的停止准则仍然基于最大似然，因此所需分量数量大于样本数据中实际高斯分量的数量。Ma[19]指出，高斯分量数量的确定等价于贝叶斯阴阳（BYI）和谐函数的最大化。BYI和谐函数及其模型选择一致性性质已在广泛条件下得到证明[20]。因此，我们采用基于BYI和谐函数的尺度增量EM算法（简称BYI-EM）来自动优化混合分量数量并估计其统计分布参数。对于最后一个局限性，利用PCA技术来解耦变量向量的元素。


本文提出了一种基于PCA混合模型的新型多模态过程监测方法。首先，假设过程数据来自若干不同的簇，每个簇对应一个操作模式，可以用一个高斯分量来表征。然后，将主成分分析应用于高斯分量的协方差以解耦变量向量的元素，从而可以通过在PCA变换空间上应用EM学习来轻松估计混合分量的参数。在缺乏先验过程知识的情况下，采用BYI尺度增量EM算法自动优化混合分量数量。利用获得的PCA混合模型，推导出一种新的过程监测方案用于多模态过程的故障检测。

本文其余部分组织如下。第2节简要回顾高斯混合模型的EM算法。第3节进一步介绍PCA混合模型和模型阶次选择方法，同时提出基于PCA混合模型的新过程监测方案。第4节展示了将所提方法应用于合成数据、连续搅拌釜加热器（CSTH）过程和田纳西伊斯曼过程（TEP）的仿真结果。最后，在文章末尾给出结论。


2. 高斯混合模型与EM算法

对于在多种条件下运行的过程，尽管均值发生偏移和/或协方差发生变化，每个操作条件服从高斯分布的假设仍然是有效的[10]。因此，高斯混合模型非常适合表示由不同操作模式驱动的数据源。

设 x 为从多模态过程记录的 m 维样本。其密度函数表示为高斯密度的凸组合，如公式 (1) 所示，其中 K 是高斯分量的数量，各分量密度 $g(x|\theta_i)$ 是由公式 (2) 给出的正态概率分布。为了构建 GMM，需要从样本数据集 X 估计未知参数集合 H 。这很困难，因为我们既不知道每个样本来自哪个分量，也不知道参数 H 。然而，著名的期望最大化（EM）算法[22]通过缺失数据的概念来处理这一困难。




给定训练样本集 X ，对数似然函数可表示为公式 (3)。参数估计问题进一步表述为公式 (4)。通常的 EM 算法通过迭代重复 E 步和 M 步来更新高斯混合的参数，直到上述对数似然函数增加到局部最大值。迭代的 E 步和 M 步按如下执行[10]。



E步

计算第 j 个训练样本在第 k 个高斯分量中的后验概率，如公式 (5) 所示。



M步

更新均值、协方差和先验概率，如公式 (6)–(8) 所示。

Data dimension	CCR (%)	ART (s)	CCR (%)	ART (s)	CCR (%)	ART (s)
$m = 2$	50	5.4574	75	4.0379	75	0.2658


然而，使用 EM 算法估计多模态操作数据的分布参数时必须考虑两个问题。（i）在工业过程中，总是有大量被测和受控变量需要监测。对于 m 维监测变量，需要估计的高斯模型参数总数为 $K * (1/2 * m^2 + 3/2 * m + 1)$ 。因此，估计参数数量非常大，EM 算法更容易陷入局部最优。（ii）由于质量平衡、能量平衡和其他操作限制，这些被测和受控变量

总是高度相关的。这导致高斯分量的协方差矩阵奇异。有必要解耦变量向量的元素并从数据中提取变量相关性。

3. 基于PCA混合模型的多模态过程监测

3.1 PCA混合模型


设 X_i 为第*i*个高斯分量的*m*维子集，其参数为 $\theta_i = \{\mu_i, \Sigma_i\}$ 。如果*m*个变量之间存在共线性，可以通过变换矩阵将其简化为一组 l_i 维特征向量，如公式(9)所示，其中 $l_i \leq m$ 是PCA分量的数量， P_i 是由 Σ_i 的第*j*大特征值对应的特征向量组成的矩阵，可以在每次EM迭代的*M*步通过奇异值分解（SVD）算法获得。PCA变换空间中的协方差矩阵和均值向量可表示为公式(10)和(11)。



由公式(10)和(11)可知，由于变换矩阵 P_i 的正交性，PCA特征向量 t_p 是解耦的。因此，其协方差矩阵是对角矩阵，对角元素对应于主特征值。移除接近零的(*m*−*l*_{*i*})个特征值减少了混合模型中需要确定的参数数量，并保证了协方差矩阵的非奇异性。由于变换矩阵 P_i 是线性的，它不会改变数据分布特征。如果保留的数据信息足够大，则公式(2)的条件密度函数可以简化为公式(12)。

Noise deviation	CCR (%)	ART (s)	CCR (%)	ART (s)	CCR (%)	ART (s)
$\sigma = 0.01$	0	1.3562	0	4.4492	100	0.1552

当E步中的条件密度函数被公式(12)替代时，不仅避免了协方差矩阵的奇异性，还加速了迭代过程。考虑到混合分量的参数在每次迭代时更新，应在*M*步中添加一个新步骤来获得新的特征值参数和相应的特征向量，如公式(13)所示。上述方程可以通过奇异值分解（SVD）算法或QR分解[4]获得。这种迭代过程在本文中称为PCA-EM算法。最终的PCA基数量可以在迭代过程完成后通过累积方差百分比（CPV）确定。




因此，可以构建PCA混合模型（简称PCAMM），如公式(14)所示，其中每个 $\theta_i = \{\mu_i, \Sigma_i, P_i\}$ 是第*i*个分量的参数集，条件密度函数由公式(12)给出。参数可以通过PCA-EM算法从训练数据集估计。然后，基于PCA过程监测中的Holling T2和SPE统计量可以很容易地扩展到PCA混合模型。采用这些统计量是很自然的，因为每个局部模型都是正态分布的。第*i*个分量的T2和SPE统计量定义为公式(15)和(16)。

Variable	Mode 1	Mode 2	Mode 3	Mode 4	Mode 5
Level SP	12	16	9	12	12


3.2 基于BYY的模型阶次选择

给定来自具有*k* > 1个高斯分量的原始混合的样本数据集*X*，初始分量数量*K* = 2。和谐函数 $J(H, K)$ 表示为公式(17)。为了提高总和谐函数值，我们可以将具有最小分量和谐值的分量（如第*r*个分量）沿第一主成分方向分裂为两个分量。两个分裂分量的参数如公式(18)–(22)所述。然后执行上述PCA-EM算法来估计*K*+1个混合分量的参数。上述分裂过程持续进行，直到总和谐函数达到最大值。



3.3 基于PCA混合模型的在线监测

现在给出基于PCA混合模型的新型多模态过程监测方法来进行在线过程监测。在在线监测中，首先利用贝叶斯推断策略计算新样本 x_t 属于每个混合分量的后验概率，如公式 (23) 所示， x_t 属于公式 (24) 所示的分量。随后，通过公式 (14) 计算监测统计量T2和SPE。考虑到每个混合分量有不同的控制限，监测所有控制图是繁琐的。因此，定义了总体T2和SPE统计量用于多模态过程的故障检测，如公式 (25) 所示。只有当所有监测统计量都小于1时，才判定过程处于正常运行状态。




4. 应用实例

4.1 合成数据

多模态过程监测的一个关键步骤是在正常操作区域周围推导置信边界。在本实验中，我们生成两个合成数据集来测试PCA混合模型估计多模态数据分布的效率。第一个数据集（名为Set

1）由七个高斯密度的混合生成[15]，变量之间没有共线性。在这种情况下，我们创建了20个不同复杂度的随机混合（见图1a-c），并从每个混合中采样1000个点作为训练集。第二个合成数据（Set 2）由公式 (26) 所示的具有变量间共线性的多元线性系统生成。



其中 $[s1, s2]^T$ 表示高斯分布数据源， $[e1, e2, e3, e4, e5]^T$ 是标准差为 $\sigma \cdot I$ 的零均值白噪声。模拟了五组数据源来表示不同的操作模式。在仿真中，每个操作模式生成200个样本，使用所有1000个样本作为数据集2。数据生成和所有算法执行20次。我们将所提PCA-EM、BYY-EM[19]和F-J EM算法[18]应用于这些数据集构建混合模型，并计算正确分类率（简称CCR）和平均运行时间（简称ART）。

对于Set 1，图1展示了三个二元高斯数据集的不同分布以及F-J EM算法和PCA-EM算法在这些数据集上的学习结果。可以验证，经过基于BYE的学习后，七个高斯分量最终被准确地定位在七个分量上。相比之下，F-J EM算法要么给出了错误的分量数量（图1d），要么收敛到错误的参数值（图1e）。表1给出了PCA-EM与F-J EM和BYE-EM算法在所有20个混合数据集上的实验结果比较。显然，基于BYE的EM算法比F-J算法具有更好的估计精度。此外，所提BYE-PCAMM比前两种方法收敛得快得多，表明PCA变换的对角化可以提高计算效率。

当这些方法应用于估计线性相关数据集（即Set 2）的分布时，如图2和表2所示，前两种EM算法由于协方差矩阵的奇异性都导致了错误的高斯分量数量。相比之下，如图2(c)所示，所提BYE-PCAMM能够以快速收敛准确地定位到五个实际高斯分量。

4.2 模拟CSTH过程

在本节中，所提基于PCA混合模型的监测方法被应用于多种操作条件下的模拟CSTH过程。CSTH仿真模型最初由Thornhill等人[23]开发。如图3所示，搅拌釜由充分混合的热水和冷水流供应，并由蒸汽加热。CSTH模型输入是热水、冷水和蒸汽阀需求，输出包括由多个PI回路控制的液位、温度、热水和冷水流量的电子测量值。

如表3所列，设计了五组操作条件来测试所提方法在监测多模态过程中的性能。本研究选择三个受控变量——液位、温度和冷水流量进行监测。在训练期间，每个操作模式以1秒采样时间收集200个样本，来自多个模式的总共1000个样本用于构建标称PCA混合模型。获得的PCA混合模型由五个高斯分量组成。每个分量的估计先验概率为0.2，与实际数据生成一致。每个分量的PCA基数为3，表明监测变量之间没有共线性。

考虑了仪表偏差故障和随机变化误差两种异常场景来测试该方法的有效性。在第一种情况下，前100个样本在正常操作模式1下模拟，然后从第101个样本到第200个样本对液位测量引入-0.5的阶跃变化。对于案例2，前100个正常样本也在第一模式下收集，但随后在温度测量中引入膨胀的随机变化[10]。

如图5(a)所示，传统PCA的SPE和T2控制图在检测案例1中的偏差故障时表现不佳。T2指标远低于其控制限，无法触发任何故障报警。相比之下，如图5(b)所示，基于PCA混合模型的监测方法中，T2和SPE指标在第100个样本之后立即清晰地指示了故障发生。在案例2中，图6(a)中基于PCA的T2和SPE图完全未能检测到随机变化故障。然而，如图6(b)所示，PCA混合模型从第101个样本开始就违反置信限检测到了故障，没有任何延迟。在这个多模态CSTH示例中，基于PCA混合模型的监测方法被证明在以较低误报警率检测不同类型传感器故障方面是有效的。

4.3 田纳西伊斯曼过程（TEP）

田纳西伊斯曼过程[24]是一个复杂工业化工过程的模型。它已被广泛用作不同目的的基准案例研究。如图7所示，该过程有五个主要单元操作：反应器、产品冷凝器、循环压缩机、汽提塔和气液分离器。四种气态反应物被送入反应器，形成两种产品以及副产物和惰性物质，通过下游操作进行分离。该过程包含12个操纵变量和41个用于监测或控制的测量变量。原始过程本身严格开环不稳定，因此必须引入某种控制策略。这里采用Ricker[25]开发的分散控制设计用于闭环过程操作。此外，如表4所列，在三种不同的G/H质量比下有六种过程操作模式。

为了实际考虑，从41个测量值中选择22个连续输出作为监测变量，采样时间为0.05小时。为了构建过程监测的标称模型，在上述每种操作模式下收集1000个样本，总共6000个样本构成训练数据集。获得的PCA混合模型由五个高斯分量组成，其中模式2和模式5由于其分布特性非常相似而可以用一个高斯分量表征。每个分量的先验概率和PCA基数分别为{0.1667, 0.1667, 0.333, 0.1667, 0.1667}和{12, 11, 4, 12, 13}。

为了检验所提监测方法对复杂工业过程的有效性,设计了三种不同故障类型的测试场景。案例1:过程最初在模式5下正常运行,然后从第101到200个样本添加IDV6(A进料突然损失)。案例2:过程最初在模式3下运行,然后在采样点100添加IDV11(反应器冷却水温度随机变化)。案例3:在模式3下正常运行约50小时后,过程操作在采样点100切换到模式1,然后在正常操作下收集100个样本,在第201个样本对模式1引入IDV13(反应动力学缓慢漂移)。

在案例1中,A进料的突然损失会导致一系列相关变量由于监测变量之间的相互作用而迅速远离正常操作区域。因此,如图9所示,全局PCA和我们提出的方法以相似的效率捕获了过程故障。对于案例2,然而,如图10(a)所观察到的,大多数故障样本在SPE和T2图中都落在95%控制限以下,表明基于PCA的方法检测率极低。在图10(b)中,PCA混合模型控制图能够在没有显著延迟的情况下检测到同一故障,证明了所提方法在检测困难的随机变化故障方面的高精度。在案例3中,全局PCA方法在处理缓慢漂移故障时仍然表现不佳。如图11(a)所示,SPE和T2控制图错过了大多数故障样本,因此具有高二类错误。相比之下,所提方法成功地在早期阶段检测到了漂移故障,仅延迟93分钟。结果表明,基于PCA混合模型的监测方法在检测缓慢漂移故障方面优于全局PCA方法。

5. 结论

过程监测问题可以被视为一类分类问题,其关键任务是准确估计正常操作区域周围的置信边界,以将正常过程数据与故障数据分离。针对具有多种操作条件的复杂工业过程,当正常操作数据服从多模态分布时,所提基于PCA混合模型的方法表现良好,该分布可以用有限高斯混合模型来表征。考虑到由于监测变量间共线性导致的协方差矩阵病态问题,将PCA技术应用于E步以解耦变量向量的元素。然后采用BYJ算法自动优化混合分量数量。与F-J

EM和BYJ-EM算法相比,所提基于PCA的EM算法具有更高的估计精度且收敛更快。利用获得的PCA混合模型,利用贝叶斯推断程序计算每个监测样本属于所有高斯分量的后验概率,并计算总体统计指标用于在线监测。CSTH和TE过程说明了所提监测方法的有效性。监测结果的比较表明,所提方法能够以正确的模型选择实现混合模型的良好参数估计,在更高检测率、更低误报警率和更短故障捕获延迟方面优于传统PCA方法。因此,所提方法为在无先验过程知识的情况下监测多种操作条件下的复杂工业过程提供了一种有前景的工具。

参考文献

- [1] Ge ZQ, Gao FR, Song ZH. Two-dimensional Bayesian monitoring method for nonlinear multimode processes. *Chem Eng Sci* 2011;66(21):5173-83.
- [2] Qin SJ. Statistical process monitoring: basis and beyond. *J Chemomet* 2003;17:480-502.
- [3] Zhao CH, Yao Y, Gao FR, Wang FL. Statistical analysis and online monitoring for multimode processes with between-mode transitions. *Chem Eng Sci* 2010;65(22):5961-75.
- [4] Sharma Alok, Paliwal Kuldip K, Imoto Seiya, Miyano Satoru. Principal component analysis using QR decomposition. *Int J Mach Learn Cybernet* 2012.
- [5] Hwang D-H, Han C. Real-time monitoring for a process with multiple operating modes. *Control Eng Pract* 1999;7:891-902.
- [6] Qin SJ. Recursive PLS algorithms for adaptive data modeling. *Comput Chem Eng* 1998;22(4-5):503-14.
- [7] Li WH, Yue HH, Sergio V-C, Qin SJ. Recursive PCA for adaptive process monitoring. *J Process Control* 2000;10(5):471-86.
- [8] Zhao SJ, Xu YM, Zhang J. A multiple PCA model based technique for the monitoring of processes with multiple operating modes. In: *Comput Aided Chem Eng*. Elsevier; 2004. p. 865-70.
- [9] Choi SW, Park JH, Lee I-B. Process monitoring using a Gaussian mixture model via principal component analysis and discriminant analysis. *Comput Chem Eng* 2004;28(8):1377-87.
- [10] Yu J, Qin SJ. Multimode process monitoring with Bayesian inference-based finite Gaussian mixture models. *AIChE J* 2008;54(7):1811-29.
- [11] Kano M, Hasebe S, Hashimoto I, Ohno H. Evolution of multivariate statistical process control: application of independent component analysis and external analysis. *Comput Chem Eng* 2004;28(6-7):1157-66.
- [12] Ge ZQ, Song ZH. Online monitoring of nonlinear multiple mode processes based on adaptive local model approach. *Control Eng Pract* 2008;16(12):1427-37.

- [13] Kim H-C, Kim D, Bang SY. An efficient model order selection for PCA mixture model. Pattern Recogn Lett 2003;24(9-10):1385-93.
- [14] Li JQ, Barron AR. Mixture density estimation. Adv Neural Inform Process Syst 2000;12:279-85.
- [15] Vlassis N, Likas A. A Greedy EM algorithm for Gaussian mixture learning. Neural Process Lett 2002;15:77-87.
- [16] Verbeek JJ, Vlassis N, Krose B. Efficient greedy learning of Gaussian mixture models. Neural Comput 2003;15(2):469-85.
- [17] Wafo Soh C. Optimal filtering of measured spectral intensity. Int J Mach Learn Cybernet 2013.
- [18] Figueiredo MAF, AK Jain. Unsupervised learning of finite mixture models. IEEE Trans Pattern Mach Intell 2002;24:381-96.
- [19] Ma JW, Wang TJ, Xu L. A gradient BYY harmony learning rule on Gaussian mixture with automated model selection. Neurocomputing 2004;56:481-7.
- [20] Ma JW. Automated model selection on finite mixtures. In: Proceedings of the 2006 international joint conference on neural networks; 2006. p. 8255-61.
- [21] Li L, Ma JW. A BYY scale-incremental EM algorithm for Gaussian mixture learning. Appl Mathemat Comput 2008;205(2):832-40.
- [22] Dempster AP, Laird NM, Rubin DB. Maximum likelihood from incomplete data via em algorithm. J Royal Stat Soc Ser B-Methodol 1977;39(1):1-38.
- [23] Thornhill NF, Patwardhan SC, Shah SL. A continuous stirred tank heater simulation model with applications. J Process Control 2008;18(3-4):347-60.
- [24] Downs JJ, Vogel EF. Plant-wide industrial process control problem. Comput Chem Eng 1993;17:245-55.
- [25] Ricker NL. Decentralized control of the Tennessee Eastman challenge process. J Process Control 1996;6:205-21.

作者简介

Xianzhen Xu

Xianzhen

Xu目前是浙江大学控制科学与工程专业的博士研究生。同时她是常熟理工学院的副教授。她的主要研究兴趣包括但不限于复杂过程的过程监测和故障诊断。

Lei Xie

Lei

Xie目前是浙江大学的副教授。2005年获得浙江大学控制科学与工程博士学位。他的主要研究兴趣包括但不限于统计学与系统理论的交叉领域。

Shuqing Wang

Shuqing Wang目前是浙江大学的教授。他的主要研究兴趣包括但不限于先进过程控制理论与技术、控制理论与应用。