

基于在线字典学习的自适应过程监测及其工业应用

Keke Huang, Yiming Wu, Cheng Long, Hongquan Ji, Bei Sun, Xiaofang Chen, Chunhua Yang

ISA Transactions, Vol. 114, 2021, pp. 399–412

摘要:

对于工业过程而言,传统过程监测方法的一个常见缺陷是,在催化剂失活、季节性波动等各种因素的影响下,会产生越来越多的误报警。为解决这一问题,本文提出了一种在线字典学习方法,能够自适应地完成过程监测和故障诊断任务。该方法利用当前可用信息来更新字典和控制限,而非保持固定的监测模型。在线字典学习方法优于传统方法:首先,与基于少量历史数据的传统离线方法相比,该方法可以通过在线字典更新来扩充训练数据,从而很好地应对时变过程;其次,该方法的计算复杂度低于使用大量数据的离线学习方法,在工业大数据时代具有吸引力;第三,该方法比现有的基于递归主成分分析的方法更加可靠,因为它可以解决递归主成分分析方法中经常遇到的主成分异常或特征向量非正交问题。最后,设计并开展了一些实验以验证在线字典学习的优势。

关键词: 自适应过程监测, 在线字典学习, 时变过程, 计算复杂度

1. 引言

随着现代信息技术的进步,工业过程变得更加智能化和自动化,系统复杂性也随之提高。因此,由于这些系统故障的级联效应,如果任何故障的检测被延迟,后果将非常严重和危险。因此,过程监测方法对工业系统来说是必要的。数据驱动的过程监测方法随着计算机技术的发展而兴起,充分利用了数据中蕴含的信息,且不需要过程模型的任何第一性原理知识[1-4]。在这些方法中,基于多元统计过程监测(MSPM)的方法对学者们非常有吸引力。主成分分析(PCA)方法采用Hotelling T²和平方预测误差(SPE或Q)联合统计量来检测故障。目前,PCA已在许多文献中得到广泛研究并取得了相当大的成功[5, 6]。除PCA外,PLS[7, 8]、ICA[9, 10]、CCA[11, 12]和CVA[13, 14]以及其他MSPM方法也被提出来克服过程监测中的各种不利因素。此外,一些最近发表的论文也关注了统计过程监测这一主题。

近年来,稀疏表示理论已被严格证明并发展得非常完善。因此,字典学习方法引起了广泛关注,并在图像处理[15]和模式识别[16]中展示了强大的表示能力。字典学习方法通过将字典的少量原子和稀疏编码矩阵线性组合来表示原始数据。最近,一些文献表明了稀疏表示学习方法在工业过程故障诊断领域的有效性,这也可以被视为一个二分类任务。例如,Ning等人[17]采用LCDL方法处理多模态过程并同时对模式进行分类。Peng等人[18]开发了一种用于多模态过程监测和模式识别的稀疏建模方法。Huang等人[19]提出了一种分布式学习方法,从变量维度方向将数据矩阵分成许多子块,并通过贝叶斯融合获得全局结果。Huang等人[20]引入了迁移字典学习来处理跨区域过程监测问题。尽管这些方法在特定问题上取得了令人满意的结果,但它们没有考虑在实际工业过程中普遍存在的时变特性。

在本文中,我们关注以时变为特征的工业过程,这在近年来已被广泛研究[21, 22]。过程的时变属性通常由催化剂失活、季节性波动、设备和传感器老化或其他因素引起。使用固定监测统计量或从训练步骤中学习的监测统计量的传统监测方法,在监测时变过程时可能导致大量报警。如果上述情况发生,监测方法的可靠性将受到严重损害。已有许多先进方法被提出,如Li等人提出了递归主成分分析(RPCA)[23],通过融合新获得的信息,可以得到特征向量和特征值矩阵的递归形式。基于这一思想,Lamiaa等人提出了一种高效RPCA[24]作为递归故障诊断方法。Qin等人将移动窗口方法集成到递归PLS算法中[25]。Jeng和Wang等人讨论了移动窗口PCA(MWPCA)[26, 27],这些工作的主要思想是在吸收新样本时丢弃旧样本的影响。他们声称MWPCA可以克服RPCA因数据点数量不足而产生的缺陷。除了统计方法外,使用移动窗口的数据挖掘方法也被用于故障检测。Zhang等人使用了基于滑动窗口的ABSAD(基于角度的子空间异常检测)[28],Ma等人采用了自适应LOF(局部离群因子)方法[29]来解决动态问题。

虽然这些方法在时变过程监测方面有一些优势,但它们也存在以下局限性。首先,基于一阶摄动的RPCA及其衍生方法,在由于累积和递归操作导致更新数据量巨大时,会面临主成分异常的问题。此外,这些基于数据挖掘的方法分析样本的几何拓扑结构(如最大方差或欧氏距离),但不能像字典学习那样直接从原始数据中提取底层特征。即时学习(JITL)是另一种常用的自适应策略,它会通过特定规则从数据库中查询相关数据样本,然后根据这些样本构建新的局部模型。JITL方法已与许多方法集成,用于完成软测量[30]、分类[31]和质量预测[32]等领域的任务。在过程监测领域,JITL也表现出色[33, 34]。然而,我们没有考虑将字典学习与JITL结合起来解决这个问题,因为这会带来巨大的时间复杂度。首先,在线学习不需要查询过程,这非常耗时,特别是当JITL数据库数量很大时。其次,采用块坐标下降算法的在线学习极其高效,而JITL每次新数据到来时都要重建模型。因此,为了实现自适应工业过程监测和字典学习方法的表示

能力，本文开发了一种在线字典学习方法，通过稀疏表示理论来应对时变过程。

2. 预备知识

2.1 递归PCA方法

RPCA方法的思想是在每个监测步骤递归地分解协方差或相关矩阵。这里，我们研究中引用的递归方法是基于一阶摄动的RPCA，最初由[35]提出，后经[36]修改。假设 $X = [x_1, x_2, \dots, x_M]$ 是初始零均值矩阵，其中 m 是数据维度， M 表示样本数量。当新的数据向量 x_{M+1} 到达时，协方差 S_{M+1} 的递归估计可由公式(1)给出，假设数据矩阵的均值保持不变以简化表达式。

Nomenclature.	
Terms	Definition
Train data	Used to construct the initial model.
Historical data	Equivalent to the train data.
Test data	Used to test the model in the offline based

然后， S_M 和 S_{M+1} 的特征分解写为公式(2)，其中 P 和 Q 分别表示标准正交特征向量和对角特征值矩阵。定义 $\alpha_{M+1} = P_M^T x_{M+1}$ ，将公式(2)代入公式(1)，得到特征向量和特征值的递归形式如公式(3)所示。

	method but available to update the model.
Abnormal data	Detected to be fault continuously.
Normal data	Detected to be normal.
Time-varying data	Detected to be fault discontinuously.
Updated data	Used to update model, including normal data

接下来， $(M-1)Q_M + \alpha_{M+1} \alpha_{M+1}^T$ 项可以继续特征分解，如公式(4)所示。将公式(4)代入公式(3)，特征值和特征向量的递归公式如公式(5)所示。

$$S_{M+1} = \frac{1}{M} \sum_{i=1}^{M+1} x_i x_i^T = \frac{M-1}{M} S_M + \frac{1}{M} x_{M+1} x_{M+1}^T$$

Then, the eigen-decompositions of S_M and S_{M+1} following formula:

$$S_M = P_M Q_M P_M^T, S_{M+1} = P_{M+1} Q_{M+1} P_{M+1}^T$$

令 $D_{M+1} = Q_M + E_{\{Q, M+1\}}$, $V_{M+1} = I + E_{\{P, M+1\}}$ ，其中 $E_{\{Q, M+1\}}$ 和 $E_{\{P, M+1\}}$ 是摄动矩阵。因此，求解 V 和 D 的问题已转化为求解 $E_{\{Q, M+1\}}$ 和 $E_{\{P, M+1\}}$ 的问题，它们的解由[36]基于一系列推导给出。 $E_{\{Q, M+1\}}$ 是对角矩阵，第 i 个对角元素是 α_i^2 ，其中 α_i 是 α_{M+1} 的第 i 个元素。对于 $E_{\{P, M+1\}}$ ，位置 (i, j) 的元素值如公式(6)所示，其中 q_i 表示 Q_M 的第 i 行第 i 列元素。因此，我们可以递归地获得数据的协方差，然后同时更新特征向量和特征值矩阵以自适应地监测过程。

$$S_{M+1}(MQ_{M+1})P_{M+1}^T = P_M[(M-1)Q_M + \alpha_{M+1}\alpha_{M+1}^T]P_M^T$$

Next, the $(M-1)Q_M + \alpha_{M+1}\alpha_{M+1}^T$ term can be decomposed continuously, namely:

$$(M-1)Q_M + \alpha_{M+1}\alpha_{M+1}^T = V_{M+1}D_{M+1}V_{M+1}^T$$

2.2 传统字典学习方法

在本小节中，将从数学角度介绍字典学习方法。稀疏表示作为一种高效的编码方法，因其强大的能力在许多领域已被证明有效。从数学上讲，如果 $X = [x_1, x_2, \dots, x_M]$ 表示从工业过程收集的样本，字典学习方法的关键任务是学习一个正交基集 $D = [d_1, \dots, d_K]$ ，也称为字典。字典原子 $\|d_i\|_2 = 1$ ， K 是原子数。通常 K 大于 m 以确保学习到的字典是过完备字典。字典学习任务对应于公式(7)所示的优化函数。

Let $D_{M+1} = Q_M + E_{Q,M+1}$ and $V_{M+1} = I + E_{P,M+1}$, $E_{Q,M+1}$ and $E_{P,M+1}$ are perturbation matrices. Thus, the problem of solving V and D has been transformed to be one of

其中 $W = [w_1, w_2, \dots, w_M]$ 表示系数矩阵, X 在字典 D 上的稀疏约束为 T 。 T 称为稀疏度水平, 表示 w_j 中非零元素的数量不能超过 T 。最近, 许多方法如 MOD、K-SVD [37] 被创建来优化公式 (7) 中的目标函数。一个核心策略是将问题分解为两个阶段, 即稀疏编码和字典更新, 然后用迭代循环交替求解。显然, 上述字典学习方法适用于固定数据集。由于工业过程数据具有时变特征, 因此需要开发在线字典学习方法, 使字典能够随流数据持续更新, 以获得准确的过程监测结果。

3. 方法论

3.1 动机

由于实际工业过程持续运行, 传感器连续收集数据, 已经收集和存储了极其大量的过程数据。有了丰富的历史数据, 如何选择训练样本是一个关键问题。为了字典学习模型的可靠性, 一种经验方法是尽可能多地使用训练数据。然而, 大量训练数据带来了高时间和空间复杂度的挑战。为解决这个问题, 一种尝试是假设从传感器收集的数据是独立同分布的 (i. i. d), 这在一定程度上有助于减少样本量。然而, 由于现实中复杂的生产环境, i. i. d 假设很难成立。此外, 工业过程通常具有由内部或外部因素引起的时变属性。在我们的论文中, 我们对待时变特征的方式类似于 [26, 28] 的工作, 忽略时变的原因, 并且只要过程仍在确定的运行范围内运行, 就将其视为正常情况。在时变条件下, 传统方法不可避免地会失去其表示能力。

3.2 提出的模型

这里详细介绍在线字典学习方法。公式 (7) 是经典的字典学习方法优化程序, 但由于训练样本是顺序到达的, 最好将其转换为如公式 (8) 所示的迭代版本。

In a series of deductions, $E_{Q,M+1}$ is diagonal matrix and its diagonal elements is α_i^2 , where α_i is the i_{th} element of α_{M+1} . $\tilde{z}_{P,M+1}$, the entry value of the position (i, j) are displayed in following equation:

此外, 有两种稀疏约束形式, 即 L_1 范数和阈值 T 。在本文中, 我们通过控制稀疏度 T 来确定稀疏水平。由于两种约束形式可以相互转换, 我们可能会根据上下文交替使用这两种表达形式。此外, 与公式 (7) 相比, 公式 (8) 可以通过迭代方法在训练数据到来时持续学习字典。同时, 公式 (7) 只在训练过程中执行一次。因此, 公式 (8) 更灵活, 更适合在线学习。

由于训练样本实时在线到达, 大多数 M 个样本无法用于优化目标函数 (8)。显然, 直接实现最小化经验代价 $f_M(D)$ 是困难的。换一种思路, 假设这里有 r 个可用数据, 我们可以通过将变量 M 替换为 r 来根据公式 (8) 训练初始模型。当第 $(r+1)$ 个样本到达时, 将通过瞄准平均误差重新计算新字典, r 变为 $r+1$ 。因此, 公式 (8) 可以转换为公式 (9) 所示的新形式, 其中 t 是迄今为止可用于更新模型的数据样本数量, 它持续变化, 其收敛性已在 [38] 的第 4 节中得到证明。

$$\tilde{z}_{P,M+1}(i, j) = \begin{cases} 0 & i = j \\ \frac{\alpha_i \alpha_j}{q_j + \alpha_j^2 - q_i - \alpha_i^2} & i \neq j \end{cases}$$

然而, 如果每次新数据到来时都优化公式 (9), 将消耗大量计算资源。因此, 下面将详细介绍基于迭代的解决方案。为了更清楚地说明优化过程, 该方法将选择一个在线数据样本 x_j 作为示例来展示在线字典更新的整个过程。当第 j 个在线数据样本 x_j 到达时 (假设所有在线数据样本目前都是正常的), 优化程序 (9) 包括稀疏编码阶段和在线字典更新阶段。

(1) 稀疏编码阶段

本部分的目标是基于 $D_{\{j-1\}}$ 计算 x_j 的稀疏编码向量 w_j 。这里 $D_{\{j-1\}}$ 是基于先前数据样本学习的字典。优化程序可表示为公式 (10), 显然可以通过正交匹配追踪 (OMP) 算法 [39] 和最小角回归 (LARS) 算法等多种优化方法求解。在本文中, 我们使用 OMP 方法解决此问题。详细的 OMP 算法如表 2 所示, 展示了近似获取稀疏向量的过程。

coding approach, has been demonstrated the effectiveness in many fields due to its strong ability. Mathematically, if $X = [x_1, x_2, \dots, x_M] \in R^{m \times M}$ denotes the collected sample from industrial process, the key task of dictionary learning method is to learn a orthogonal basis set $D = [d_1, \dots, d_K] \in R^{m \times K}$, which also can be

(2) 字典更新阶段

获得稀疏编码后，下一阶段是计算字典

D_j 。直观地说，公式(9)可以转换为公式(11)。从这个方程可知，如果需要计算更新后的字典，则需要一个初始字典。与大多数文献的做法一样， D_{j-1} 被用来初始化字典更新目标函数(11)的字典。这种操作称为热启动，既方便又高效。

$$\begin{aligned} & \text{learning task corresponds to an optimization function that takes} \\ & \text{the following form:} \\ & (D, W) = \arg \min_{D, W} \|X - DW\|_F^2; \quad \text{s.t.} \quad \forall i, \quad \|w_i\|_0 \leq T \quad (7) \\ & \text{where } W = [w_1, w_2, \dots, w_M] \in R^{K \times M} \text{ denotes the coefficient} \end{aligned}$$

In addition, then norm and threshold level by controlling

公式(11)由于求和操作似乎难以优化。幸运的是，通过矩阵的迹和F-范数的转换，该形式可以简化。经过一系列变换和简化，优化程序(11)可以转换为公式(12)所示的形式，其中 $A_j = A_{j-1} + (1/2)w_j * w_j^T$, $B_j = B_{j-1} + x_j * w_j^T$ ，它们可以被称作信息矩阵，因为它们能够保存从开始到现在的信息。由于篇幅限制，详细推导可参见附录。

the new dictionary will be calculated again until average error, and number r changes to $r + 1$ be transferred to a new form as follows:

$$\hat{f}_t(D) = \min_{D, w} \frac{1}{t} \sum_{i=1}^t \left(\frac{1}{2} \|x_i - Dw_i\|_2^2 \right)$$


Aharon等人[40]和Zhao等人[41]采用投影一阶随机梯度下降法来解决这个问题。此外，Bertsekas[42]提出了块坐标下降法。与投影梯度下降法相比，块坐标下降法是无参数的，不需要任何学习率参数。因此，我们在本文中采用块坐标下降法，其过程如表3所示。两个阶段完成后，我们获得了包含丰富在线数据信息的新字典 D_j 。之后，当 x_{j+1} 到达时，我们重复对 x_j 执行的程序并获得 D_{j+1} 。

3.3 用于过程监测的在线学习策略

本节详细讨论在线字典学习如何应用于过程监测。它也可以分为两部分：训练初始化字典和在线监测与更新。这里值得一提的是，更新过程包括字典更新和控制限更新（控制限是指决定数据样本是否故障的阈值）。在实际工业过程中会产生和存储大量历史数据样本，我们应该尝试选择一小部分高质量数据点作为历史数据集，以避免缺失值、异常值或其他因素的影响。然后，我们使用传统字典学习方法基于历史数据集训练原始字典 D_0 。算法2采用热启动策略，但仍然需要一个起始字典， D_0 充当这个角色。当第一个在线数据样本到达时，必须将初始化字典作为程序的输入。

此外，我们采用核密度估计（KDE）[9]算法计算控制限。首先应通过将起始字典 D_0 和历史数据集结合起来计算历史数据的重建误差，然后可以借助KDE工具箱在一定置信水平 α 下设置控制限 R_{tr} 。

值得一提的是，在线监测和更新对应于一个迭代过程。以 x_J 为例（意味着前J-1个样本包含j-1个更新样本），首要任务是故障检测。因此，我们使用第(j-1)次更新迭代中学习的字典 D_{j-1} ，根据最经典的稀疏模型计算新在线样本 x_J 的稀疏编码，如公式(15)所示。公式(15)可以通过OMP方法求解。获得稀疏编码后，我们得到重建样本如公式(16)所示。获得重建结果后，在线重建误差（OLRE）的计算顺理成章，如公式(17)所示。然后我们可以通过将 $OLRE_J$ 与最新阈值 R_{tr} 比较来确定数据样本 x_J 是正常的还是故障的。



值得注意的是，由于时变属性，当OLRE_J > R_tr时，样本不能总是被分类为故障样本。实际上，我们应用常用规则，通过检查该样本是否是若干连续失控样本中的最后一个来确定样本是否故障[28, 29]。

至于更新过程，如果x_J被分类为故障数据点，我们理所当然地放弃更新任何变量。然而，如果样本未被分类为故障样本，它将被划分为更新数据。对于时变数据，即过程中存在缓慢变化的样本，该样本应具有重要信息。此外，控制限应随过程自适应更新。在本文中，我们利用KDE方法获得新的控制限。因此，对于时变数据，字典和控制限都需要重新更新。由于KDE方法的高计算复杂度，当样本被分类为正常样本时，只有字典是需要更新的变量。为了更直观地展示测试数据分类策略，一些细节总结在表4中。

为了探索故障数据的可能原因，执行故障隔离任务。考虑到我们的问题，引入稀疏贡献图（SpCP）方法[17]来承担此任务。假设过程中发生了一类故障，数据可表示为公式(18)，其中D是当前的在线字典，I是单位矩阵，故障信息由f表示。为简单起见，定义D_bar = [D, I]，并通过公式(19)计算新异常样本x_new的稀疏编码。选择算子定义为P = [0, I]，因此通过Pw_new选择w_new的最后m个元素。第i个变量的故障稀疏贡献按公式(20)计算。

sparse coding stage

of this part is to calculate the sparse code vector w_j of D_{j-1} . Here, D_{j-1} is the dictionary that has been learned on previous data samples. The optimization program could

4. 仿真结果

4.1 时变数学仿真算例

一方面，在线字典学习最有意义的影响是合理融合导致低误报警率（FAR）的时变信息。为了展示所提方法在降低FAR方面的有效性，我们稍微修改了Ma等人[29]使用的数值仿真模型来生成第i个样本数据。详细公式如公式(21)所示。其中N是正态分布，U是均匀分布。基于公式(21)的模拟数据生成过程可以分解为三个步骤。

$$\begin{aligned} &\text{be expressed as follows:} \\ &w_j = \arg \min_w \frac{1}{2} \|x_j - D_{j-1} w\|_2^2 \\ &\text{s.t. } \|w\|_0 \leq T \end{aligned} \quad (10)$$

数据收集：收集200个训练样本作为历史数据。测试数据包括1800个正常样本和500个故障样本。在x4变量上从第2001个样本开始发生偏差为-4的偏差故障。此外，为了更好地模拟时变系统，从第1001个样本到结束，在A(1, 2)和A(2, 2)上分别添加了缓慢漂移0.003(i-1000)和0.002(i-1000)。总共生成2500个样本，其中2000个正常，500个故障数据样本。

模型参数初始化：样本收集完成后，使用普通字典学习方法基于历史数据训练初始字典。然后计算重建误差并用于计算基于KDE方法的初始化阈值

R_tr。参数设置方面，稀疏度和字典大小分别设置为2和20。PCA方法的主成分数量通过常用的累积百分比方差（CPV）确定，CPV阈值为

85%。KDE的置信水平为98%，自适应方法的连续失控标志均设置为2。

在线监测、更新和隔离：获得初始字典后，测试样本逐个到来。我们使用字典计算稀疏编码以获得当前OLRE。通过将OLRE与当前阈值比较，确定该样本是正常还是异常。然后根据测试数据的分类（异常、正常或时变），决定更新哪个组件。

RPCA方法[36]、MWPCA方法[26]、离线字典学习和在线字典方法的图形监测结果如图3所示，其中红线代表动态阈值，蓝线代表监测统计量。DRE是字典重建误差，用作离线字典学习方法判断样本状态的指标。 $rT2$ 、 rQ 、 $mT2$ 和 mQ 分别表示RPCA方法和MWPCA方法的T2和Q指标。由于故障明显，除RPCA和MWPCA基于T2统计量的方法外，所有方法的FDR都令人满意。由于过程具有时变特征，我们更关注FAR指标。从图3中可以发现，离线字典学习方法的性能最差，即FAR超过20%。

相比之下，所提方法和MWPCA基于方法可以处理缓慢时变的负面影响，它们的FAR分别为2.89%、0.06%和2.44%。虽然MWPCA基于方法在 mQ 统计量方面表现优异且FAR较低，但由于未能扩大正常和异常样本之间的区分度，它们的FDR较低。此外，RPCA比MWPCA方法有更令人满意的结果。然而，与MWPCA类似，它们的结果在随机数据样本和固定参数的一系列实验中不稳定。

对于故障隔离任务，图4直观地说明了故障发生在第四维度，因为其他变量的贡献接近零，而 x_4 的贡献最高。因此，可以得出结论：所提方法准确地完成了故障隔离任务。

4.2 大规模数据数学仿真算例

在本节中，我们展示所提方法在大规模数据过程监测中的优势。众所周知，离线字典学习方法不可避免地会导致大规模数据的高计算量。相比之下，所提方法将复杂的训练过程简化为几乎与测试具有相同时间复杂度的过程，因此能够处理大量数据，使其对实际工业过程非常实用。我们设计了一个实验来比较在线和离线字典学习方法的运行时间。

首先生成大小为200的历史数据用于构建初始字典。离线方法使用所有5200个样本来学习字典，而在线方法使用前200个样本学习初始字典，剩余5000个样本通过在线策略更新字典。在线数据样本大小分别为50,000、100,000、150,000和200,000进行了四次实验。从图5可以方便地观察到，离线字典学习方法的时间成本远远超过在线方法。随着样本数量的增加，两种方法之间的时间差距将越来越大。此外，所提方法的时间消耗几乎与数据大小成线性关系，因此可以扩展到实际应用中。

4.3 CSTR过程

这里，使用模拟基准过程即非等温连续搅拌釜反应器（CSTR）系统[43]测试所提方法。CSTR的示意图如图6所示。该过程是从与溶剂预混合的反应物A到产物B的一级反应。该过程可以用公式(23)–(26)描述。仿真运行350分钟，采样频率为每秒一次，总共有21,000个观测点。我们选择四个变量作为监测目标： C ， T ， T_c ， F 。为了模拟过程中的缓慢漂移行为，反应釜中反应混合物的体积缓慢减少。此外，在100分钟时引入斜率为每分钟-0.04的缓慢过程变化。在250分钟时对输入参数 C 添加偏差为1.0的偏差故障。

基于上述实验设置，从正常状态选择2000个数据点作为训练数据集，从正常和异常状态选择5000个作为测试数据。离线和在线字典原子均设置为20，稀疏约束设置为2。CPV阈值为80%。置信水平为99%，连续标志为2。本节的检测结果与数值算例相似。离线学习有高误报警率，而在线学习的FAR仅为0.7%。对于FDR，只有RPCA- $rT2$ 统计量可以检测所有故障。关于故障隔离， x_3 和 x_4 的贡献都很显著，这与故障设置的描述一致。因此，我们可以确认在线字典学习方法成功隔离了两个故障变量。

5. 铝电解过程应用

在现代铝电解工业中，确保过程在正常运行状态工作对保证充足生产非常重要。因此，铝电解过程监测变得重要且必要。随着传感器技术的发展，许多观测样本可以被收集。虽然这些数据样本可用于监测过程，但由于铝电解过程通常涉及强耦合和时变特征，获得准确且鲁棒的过程监测结果是一个具有挑战性的问题。阳极电流成为铝电解过程监测中最广泛使用的信号。这里选择了阳极电流信号来验证在线字典学习的过程监测性能。

为了验证所提方法的优越性和实用性，选择了正常样本和铝液虹吸样本作为监测数据。这里，数据样本的三个变量（第6、13和15个）与铝液虹吸相关。我们首先收集1000个正常样本作为历史数据来构建初始化模型。然后，选择1200个正常数据和200个铝液虹吸状态的异常数据作为测试数据。总共1400个测试样本。稀疏度和字典大小分别设置为8和30。对于MWPCA方法，CPV设置为0.8。置信水平为95%，连续标志为2。故障隔离在第1300到1399个测试样本上进行。

图10展示了所有方法的铝电解过程监测结果，图11展示了平均故障隔离结果。从图10可以看出，由于实际过程的高复杂性，离线字典学习方法产生了许多误报警，FAR达到17.75%。相比之下，由于所提在线字典学习方法可以处理实际环境中的时变属性，其FAR仅为1%。RPCA对任何统计量都有接近0%的FAR，但由于控制限过高而无法检测到任何故障。MWPCA的mT2统计量表现最完美，但mQ仅检测到约41%的故障样本。根据PCA方法的原理，我们可以认为所提方法在实际工业过程上效果更好。根据图11(a)和(b)，可以得出结论：第6、13和15个变量的贡献显著更高，它们将被识别为异常变量，这与实际情况相符。

6. 结论

时变行为在实际工业过程中极为常见，常常导致传统过程监测方法的失败。因此，我们开发了一种在线字典学习方法来自适应地执行时变过程监测。所提方法可以显著提高过程监测的性能，特别是在降低过程监测方案中的误报警方面。所提方法包括两个步骤：训练模型和过程监测。对于训练步骤，主要目标是获得初始字典和控制限，其效率与传统方法相当。对于过程监测步骤，目标是为新到达的数据样本计算误差，并将误差与控制限进行比较。一旦获取了新数据的状态，我们可以决定是否更新字典和控制限。通过上述策略，所提在线字典学习方法可以实时学习可用信息并实现自适应过程监测。一些仿真实验和实际工业过程案例的开展验证了所提方法的优越性。此外，我们计划探索在线监测过程中新数据样本的移动窗口和加权方法，因为移动窗口可以移除不具代表性的过时数据，加权可以增加重要样本的比例。此外，用于详细指导后续操作的时变状态分析或追踪也将是我们未来的研究兴趣。

附录

在本附录中，将展示从公式(11)到公式(12)的详细变换。为了方便推导开始，公式(11)再次展示。显然，D的优化与最后一项无关。此外，L2范数可以直接转换为迹形式。因此，公式(27)被重写为公式(28)。然后，在矩阵乘法的帮助下展开公式(28)得到公式(29)。该项与字典更新过程无关，因此公式(29)可以整合和简化为公式(30)。由于一系列矩阵的迹之和等于和矩阵的迹，我们可以得到关于D的新公式(31)。接下来，信息矩阵 A_j 和 B_j 实际上是各项的总和，因此公式(31)可以通过替换符号简化为公式(32)。显然，转置关系成立，且 $\text{Tr}(A) = \text{Tr}(A^T)$ 。因此可以简化为目标函数公式(33)所示的格式。最后，公式(33)需要交换矩阵的位置，因为我们有等式 $\text{Tr}(MN) = \text{Tr}(NM)$ 。现在可以找到公式(34)，它与公式(12)完全相同。

参考文献

[1] Huang B. Bayesian methods for control loop monitoring and diagnosis. J Process Control 2008;18(9):829–38.

[2] Jiang Q, Yan X, Huang B. Performance-driven distributed PCA process monitoring based on fault-relevant variable selection and Bayesian inference. IEEE Trans Ind Electron 2016;63(1):377–86.

[3] Zhao C, Gao F. A sparse dissimilarity analysis algorithm for incipient fault isolation with no priori fault information. Control Eng Pract 2017;65:70–82.

[4] Qin SJ. Survey on data-driven industrial process monitoring and diagnosis. Annu Rev Control 2012;36(2):220–34.

[5] Zhao C, Wang W, Qin Y, Gao F. Comprehensive subspace decomposition with analysis of between-mode relative changes for multimode process monitoring. Ind Eng Chem Res 2015;54(12):3154–66.

[6] Li N, Guo S, Wang Y. Weighted preliminary-summation-based principal component analysis for non-Gaussian processes. Control Eng Pract 2019;87:122–32.

- [7] Yin S, Ding SX, Xie X, Luo H. A review on basic data-driven approaches for industrial process monitoring. *IEEE Trans Ind Electron* 2014;61(11):6418–28.
- [8] Tong C, Lan T, Yu H, Peng X. Distributed partial least squares based residual generation for statistical process monitoring. *J Process Control* 2019;75:77–85.
- [9] Ge Z, Song Z. Process monitoring based on independent component analysis-principal component analysis (ICA-PCA) and similarity factors. *Ind Eng Chem Res* 2007;46(7):2054–63.
- [10] Tong C, Lan T, Shi X. Ensemble modified independent component analysis for enhanced non-Gaussian process monitoring. *Control Eng Pract* 2017;58:34–41.
- [11] Chen Z, Yang C, Peng T, Dan H, Li C, Gui W. A cumulative canonical correlation analysis-based sensor precision degradation detection method. *IEEE Trans Ind Electron* 2018;66(8):6321–30.
- [12] Chen Z, Cao Y, Ding SX, Zhang K, Koenings T, Peng T, et al. A distributed canonical correlation analysis-based fault detection method for plant-wide process monitoring. *IEEE Trans Ind Inf* 2019;15(5):2710–20.
- [13] Chen Z, Ding SX, Zhang K, Li Z, Hu Z. Canonical correlation analysis-based fault detection methods with application to alumina evaporation process. *Control Eng Pract* 2016;46:51–8.
- [14] Russell EL, Chiang LH, Braatz RD. Fault detection in industrial processes using canonical variate analysis and dynamic principal component analysis. *Chemometr Intell Lab Syst* 2000;51(1):81–93.
- [15] Elad M, Aharon M. Image denoising via sparse and redundant representations over learned dictionaries. *IEEE Trans Image Process* 2006;15(12):3736–45.
- [16] Gu S, Zhang L, Zuo W, Feng X. Projective dictionary pair learning for pattern classification. In: *Advances in neural information processing systems*. 2014, p. 793–801.
- [17] Ning C, Chen M, Zhou D. Sparse contribution plot for fault diagnosis of multimodal chemical processes. *IFAC-PapersOnLine* 2015;48(21):619–26.
- [18] Peng X, Tang Y, Du W, Qian F. Multimode process monitoring and fault detection: A sparse modeling and dictionary learning method. *IEEE Trans Ind Electron* 2017;64(6):4866–75.
- [19] Huang K, Wu Y, Wen H, Liu Y, Yang C, Gui W. Distributed dictionary learning for high-dimensional process monitoring. *Control Eng Pract* 2020;98:104386.
- [20] Huang K, Wen H, Zhou C, Yang C, Gui W. Transfer dictionary learning method for cross-domain multimode process monitoring and fault isolation. *IEEE Trans Instrum Meas* 2020;69(11):8713–24.
- [21] Choi SW, Martin EB, Morris AJ, Lee I-B. Adaptive multivariate statistical process control for monitoring time-varying processes. *Ind Eng Chem Res* 2006;45(9):3108–18.
- [22] Elshenawy LM, Awad HA. Recursive fault detection and isolation approaches of time-varying processes. *Ind Eng Chem Res* 2012;51(29):9812–24.
- [23] Li W, Yue HH, Valle-Cervantes S, Qin SJ. Recursive PCA for adaptive process monitoring. *J Process Control* 2000;10(5):471–86.
- [24] Elshenawy LM, Yin S, Naik AS, Ding SX. Efficient recursive principal component analysis algorithms for process monitoring. *Ind Eng Chem Res* 2009;49(1):252–9.
- [25] Qin SJ. Recursive PLS algorithms for adaptive data modeling. *Comput Chem Eng* 1998;22(4–5):503–14.
- [26] Jeng J-C. Adaptive process monitoring using efficient recursive PCA and moving window PCA algorithms. *J Taiwan Inst Chem Eng* 2010;41(4):475–81.
- [27] Wang X, Kruger U, Irwin GW. Process monitoring approach using fast moving window PCA. *Ind Eng Chem Res* 2005;44(15):5691–702.
- [28] Zhang L, Lin J, Karim R. Sliding window-based fault detection from high-dimensional data streams. *IEEE Trans Syst Man Cybern: Syst* 2017;47(2):289–303.
- [29] Ma Y, Shi H, Ma H, Wang M. Dynamic process monitoring using adaptive local outlier factor. *Chemometr Intell Lab Syst* 2013;127:89–101.
- [30] Jin H, Chen X, Yang J, Wu L. Adaptive soft sensor modeling framework based on just-in-time learning and kernel partial least squares regression for nonlinear multiphase batch processes. *Comput Chem Eng* 2014;71:77–93.
- [31] Alippi C, Boracchi G, Roveri M. A just-in-time adaptive classification system based on the intersection of

confidence intervals rule. *Neural Netw* 2011;24(8):791–800.

- [32] Zheng W, Liu Y, Gao Z, Yang J. Just-in-time semi-supervised soft sensor for quality prediction in industrial rubber mixers. *Chemometr Intell Lab Syst* 2018;180:36–41.
- [33] Cheng C, Chiu M-S. Nonlinear process monitoring using JITL-PCA. *Chemometr Intell Lab Syst* 2005;76(1):1–13.
- [34] Jiang Q, Yan X. Just-in-time reorganized PCA integrated with SVDD for chemical process monitoring. *AIChE J* 2014;60(3):949–65.
- [35] Champagne B. Adaptive eigendecomposition of data covariance matrices based on first-order perturbations. *IEEE Trans Signal Process* 1994;42(10):2758–70.
- [36] Erdogmus D, Rao YN, Peddaneni H, Hegde A, Principe JC. Recursive principal components analysis using eigenvector matrix perturbation. *EURASIP J Appl Signal Process* 2004;2004:2034–41.
- [37] Aharon M, Elad M, Bruckstein A, et al. K-SVD: An algorithm for designing overcomplete dictionaries for sparse representation. *IEEE Trans Signal Process* 2006;54(11):4311.
- [38] Mairal J, Bach F, Ponce J, Sapiro G. Online dictionary learning for sparse coding. In: *Proceedings of the 26th annual international conference on machine learning*. ACM; 2009, p. 689–96.
- [39] Pati YC, Rezaiifar R, Krishnaprasad PS. Orthogonal matching pursuit: Recursive function approximation with applications to wavelet decomposition. In: *Signals, systems and computers, 1993*. IEEE; 1993, p. 40–4.
- [40] Aharon M, Elad M. Sparse and redundant modeling of image content using an image-signature-dictionary. *SIAM J Imaging Sci* 2008;1(3):228–47.
- [41] Zhao B, Fei-Fei L, Xing EP. Online detection of unusual events in videos via dynamic sparse coding. In: *CVPR 2011*. IEEE; 2011, p. 3313–20.
- [42] Bertsekas DP. Nonlinear programming. *J Oper Res Soc* 1997;48(3):334.
- [43] Yoon S, MacGregor JF. Fault diagnosis with multivariate statistical models part I: using steady state fault signatures. *J Process Control* 2001;11(4):387–400.
- [44] Choi SW, Lee C, Lee J-M, Park JH, Lee I-B. Fault detection and identification of nonlinear processes based on kernel PCA. *Chemometr Intell Lab Syst* 2005;75(1):55–67.
- [45] Yang C, Zhou L, Huang K, Ji H, Long C, Chen X, et al. Multimode process monitoring based on robust dictionary learning with application to aluminium electrolysis process. *Neurocomputing* 2019;332:305–19.