

基于模式匹配和相似性保持字典学习的自适应多模态过程监测

Keke Huang, Zui Tao, Yishun Liu, Bei Sun, Chunhua Yang (Fellow, IEEE), Weihua Gui, Shiyun Hu (Senior Member, IEEE)

IEEE TRANSACTIONS ON CYBERNETICS, VOL. 53, NO. 6, JUNE 2023

摘要:

在实际工业过程中, 制造策略和生产技术的变化等因素导致了多模态工业过程的产生和新工况的不断涌现。尽管工业SCADA系统积累了大量历史数据, 可在一定程度上用于多模态过程的建模和监测, 但从历史数据学习到的模型难以适应新出现的工况, 导致模型失配。另一方面, 利用新工况数据更新模型可以使模型不断匹配新工况, 但可能导致模型失去对历史工况的表征能力, 即产生“灾难性遗忘”。为解决这些问题, 本文提出了一种联合模式匹配和相似性保持字典学习 (JMSDL) 方法, 通过学习新工况数据来更新模型, 使模型能够自适应地匹配新出现的工况。同时, 提出了相似性度量以保证所提方法对历史数据的表征能力。数值仿真实验、CSTH过程实验和工业焙烧过程实验表明, 所提JMSDL方法能够在准确匹配新工况的同时保持对历史工况的性能。此外, 所提方法在故障检测率和误报率方面显著优于现有方法。

关键词: 自适应模型更新、字典学习、模型失配、多模态过程建模、过程监测

1. 引言

如今, 工业过程变得越来越复杂, 这导致大规模工业生产中的小故障可能对整个系统造成巨大损害。此外, 大多数实际工业过程在极端条件下进行, 如高温或高压。某些故障可能导致有毒气体泄漏、火灾和爆炸等工业事故, 造成经济损失和人员伤亡。过程监测可以获取工业过程的当前状态, 当监测到故障时, 将触发相应警报以提醒操作人员及时处理故障[1]–[4]。因此, 为工业过程引入有效的过程监测方法尤为重要。

过程监测已成为一个主要研究课题, 已提出多种方法。过程监测方法可分为三类: 1) 基于模型的方法; 2) 基于知识的方法; 3) 数据驱动的方法。基于模型的方法基于工业生产机制建立模型[5], 适用于具有充分机理知识的小型系统。基于知识的方法基于专家知识或经验建立模型。通常这很耗时, 且存在经验知识不够准确可靠的场景。数据驱动的方法不需要精确的第一性原理模型和广泛的工艺知识, 仅依赖采集的数据来建立数学模型, 简单且通用。此外, 随着计算机和传感器技术的发展, 大量过程数据被采集, 为数据驱动的过程监测提供了足够的信息。因此, 数据驱动方法在现代复杂工业过程中得到广泛应用[6], [7]。

数据驱动的过程监测领域已取得一些重要进展。Li等人[8]提出了基于主成分分析 (PCA) 的过程监测方法, 推动了多元统计过程监测 (MSPM) 的发展。一些典型的MSPM方法受到了广泛关注[9]–[11]。Chen和Ge[12]创新性地开发了SVM树和SVM森林算法用于不平衡过程监测。Jiang等人[13]将贝叶斯分析应用于工业数据监测。这些工作体现了机器学习在过程监测领域的可塑性。




图1. 单模态和多模态数据可视化。(a) 单模态数据的主成分。(b) 多模态数据的主成分。对于多模态数据, 不同工况呈现不同的分布。

字典学习是一种强大的机器学习方法, 其目标是训练一个具有数据表征能力的字典。字典矩阵的每一列称为一个原子, 使用少量原子来线性表征数据。字典学习不断发展以提高其有效性, 已提出K-SVD方法[14]、标签一致K-SVD方法[15]、监督字典学习方法[16]和判别K-

SVD方法[17]。一些工作考虑了原子的物理意义，如低秩、非平稳等，将这些物理约束施加于字典原子并取得了良好效果[18], [19]。但在本工作中，原子被视为抽象特征。

字典学习在过程监测领域有广泛应用。Peng等人[20]提出了一种基于稀疏建模和字典学习的方法，用于监测具有多种工况的非高斯过程。Huang等人[21]提出了一种分布式字典学习方法，用于有效监测具有复杂、分布式和高维特征的现代工业过程。Huang等人[22]提出了一种核字典学习方法用于非线性过程监测。

在过程工业中，工况定义为某一操作条件下的过程。实际工业过程的工况会因市场需求、产品规格、原材料、制造策略和外部环境波动等因素而变化，导致新工况不断产生[23], [24]。以中国湖南某锌冶炼厂的焙烧过程为例，由于不同时期的过程指标和制造策略，焙烧过程可分为高效工况和健康工况。如果按化学反应对焙烧过程工况进行分类，可分为过度分解工况、欠氧化工况和床层沉积工况。因此，焙烧过程数据具有复杂的工况特征。

多模态数据难以建模和监测，因为其不同工况具有不同的分布特征，如图1所示。为解决这一问题，目前有三类方法，包括多模型方法、全局建模方法和在线模型更新方法。

多模型方法的理念很直接，即使用多个模型匹配每个工况，因其思路简单且性能良好而被广泛使用。Zhao等人[25]提出了多PCA方法来监测具有多种操作工况的工业过程。Natarajan和Srinivasan[26]提出了一种多模型方法来监测油气生产过程的状态。Zhao等人[27]提出了一种多阶段统计分析方法来监测青霉素培养过程。然而，多模型方法也有明显的缺点。如果新工况不断产生，模型数量将不断增加，空间复杂度很高。此外，此类方法通常需要大量时间在在线监测数据到来时找到最合适的模型匹配数据。

全局建模方法致力于建立一个单一模型来同时表征所有工况的数据。Hwang和Han[28]提出了一种基于层次聚类 and PCA的多工况过程监测方法。Xu等人[29]提出了PCA混合模型用于多模态过程中各种故障的早期检测。Ning等人[30]提出了一种标签一致字典学习（LCDL）方法用于化学工业监测。全局建模方法解决了多模型方法中模型数量过多的问题。然而，当工况数量很大时，训练样本数量也会非常大，导致训练耗时。此外，由于统计平均效应，全局模型可能无法准确表征每个工况。而且，当新工况出现时，之前训练的模型不能再使用，需要将新工况数据加入训练集重新训练模型，这是一个非常繁琐且耗时的过程。

在线模型更新方法使模型能够不断适应新工况。此类方法通常使用历史数据训练初始模型，然后使用新出现工况的数据在线更新模型，使模型对新工况数据具有良好的表征能力。Jeng[31]提出了递归PCA和滑动窗口PCA技术来在线更新模型和控制限。Huang等人[32]开发了基于在线字典学习（ODL）的过程监测技术。此类方法实现了模型更新，解决了新工况出现时需要重新训练模型的问题。然而，在线模型更新方法往往不能适应工况变化较大的过程。此外，一些在线模型更新方法可能面临“灾难性遗忘”问题，即随着模型不断更新，它可能失去表征之前工况数据的能力。

图2显示了ODL方法对图1中多模态数据的重构结果。随着模型的更新，它对之前数据的重构误差增大，这是“灾难性遗忘”的典型现象。“灾难性遗忘”的原因是模型在更新或重新训练时可能覆盖了之前学到的知识。这给过程监测带来了困难。如果更新后的模型出现“灾难性遗忘”，之前的工况将无法再被监测。




图2. ODL方法的“灾难性遗忘”现象[32]。随着新工况数据的不断学习，模型忘记了如何表征之前的数据，导致重构误差增大。

为解决工况不断增加的多模态过程监测问题，同时消除“灾难性遗忘”的负面影响，本文提出了一种联合模式匹配和相似性保持字典学习（JMSDL）方法。过完备字典在字典学习中被广泛使用，这使得字典中有足够的冗余空间来存储多个工况的特征。因此，字典学习在处理多模态数据方面具有明显优势，仅使用一个字典就能表征多个工况的数据。

我们的方法首先使用K-SVD方法[14]在第一个工况的数据上训练初始模型。当新工况出现时，仅使用新工况的数据通过JMSDL方法更新字典，使字典能够表征新工况的数据而不失去对历史工况数据的表征能力。通过依次使用所有工况的数据更新字典，我们最终获得一个能够表征所有工况的字典，并用它来监测多模态过程。本文的主要贡献如下：

- 1) 本文提出了JMSDL方法，通过最小化新工况数据的重构误差来自适应更新过程监测模型，以确保模型匹配。
- 2) 所提JMSDL方法通过在优化函数中提出保持项来克服“灾难性遗忘”，确保模型更新前后的相似性。
- 3) 所提JMSDL方法为多模态过程监测提供了一个自适应新工况的持续学习框架。

本文的其余部分结构如下。第二节详细介绍具体方法。第三节数值仿真和CSTH过程示例用于验证所提方法在数据表征和过程监测方面的优越性。第四节介绍了基于JMSDL的过程监测方法在实际焙烧过程中的应用。最后，第五节给出结论。

II. 方法论

A. 离线建模

整个离线建模过程可分为两部分：1) 初始建模和2) 自适应模型更新。首先，采集多模态数据。在数学上，数据集表示为 $X = [X_1, X_2, \dots, X_s]$ ，共有 s 个工况。对于每个工况， $X_i = [x_1, x_2, \dots, x_M] \in \mathbb{R}^{(m \times M)}$ ， $i = 1, \dots, s$ 。 m 和 M 分别表示维度和样本数。

在初始建模阶段，使用第一个工况的数据 X_1 基于传统字典学习方法训练初始字典。在自适应模型更新阶段，仅使用新工况的数据基于所提JMSDL方法更新字典。更新后的字典可以表征新工况和历史工况的数据。本节将分两部分详细描述离线阶段多模态工业过程数据的建模过程。

1) 初始建模：

字典学习的任务是学习一个字典 $D = [d_1, d_2, \dots, d_K] \in \mathbb{R}^{(m \times K)}$ ，其中 K 表示原子数。为便于搜索最优原子，对每个原子进行单位化处理，即 $\|d_i\|_2 = 1$ ， $i = 1, \dots, K$ 。字典学习使用少量原子线性重构数据，即 $x_i \approx Dw_i$ 。 w_i 是稀疏编码向量。扩展到整个数据集，即 $X_1 \approx DW$ 。 $W = [w_1, w_2, \dots, w_M] \in \mathbb{R}^{(K \times M)}$ 称为稀疏编码矩阵。字典学习的优化问题如下：

dataset is denoted as $X = [X_1, X_2, \dots, X_s]$, with a total of modes. For each of these modes, $X_i = [x_1, x_2, \dots, x_M] \in \mathbb{R}^{n \times M}$, $i = 1, \dots, s$. m and M denote the dimensionality and

其中 $\|X_1 - DW\|_F^2$ 表示重构误差。 $\|\cdot\|_F$ 表示矩阵的Frobenius范数。如果 $A = [a_{ij}]_{m \times n}$, $\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2}$ 。最小化重构误差确保字典对数据具有足够的表征能力。 $\|w_i\|_0$ 是向量 w_i 的L0范数，计算向量中非零值的数量。 T 表示稀疏度。对编码向量的L0范数约束确保用于重构数据的原子不超过 T 个。

在数学上，通常用L1范数近似替代L0范数，并将(1)的约束优化问题转化为无约束优化问题：

where $\|X_1 - DW\|_F^2$ denotes reconstruction error. $\|\cdot\|_F$ denotes the Frobenius norm of the matrix. If $A = [a_{ij}]_{m \times n}$, $\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2}$. Minimizing the reconstruction error ensures that the dictionary has adequate representation ability to the data. $\|w_i\|_0$ is the L_0 norm of the vector w_i , which counts the num-

式(2)中有两个优化变量 D 和 W ，它们不是联合凸的，可以通过交替迭代方法求解，每次迭代步骤分别求解当前最优的 D 和 W 。优化 D 时固定 W ，使用K-SVD方法[14]求解当前最优 D ；优化 W 时固定 D ，使用正交匹配追踪（OMP）方法[33]求解当前最优 W 。当达到足够迭代次数或满足收敛条件时，获得具有足够数据表征能力的字典。

初始字典 D 对工况1的数据具有良好的表征能力。实际上，我们采集了多个工况的数据，但训练初始字典时仅使用了工况1的数据。我们不使用多工况数据训练初始字典，是因为K-SVD方法是针对单模态数据的方法。如果强行使用多模态数据，由于统计平均效应，字典很可能无法很好地表征所有工况。为了使字典最终具有表征多模态数据的能力，在获得初始字典后，将使用其他工况的数据自适应地更新字典。

2) 自适应模型更新：

在实际工业过程中，由于工况的变化，模型往往无法匹配过程的每个阶段，因此需要更新模型。然而，通常无法在模型更新中使用所有历史数据。这是因为随着工业过程的持续运行，可用数据越来越多，导致更新占用大量资源。此外，在工业现场，过时的历史数据可能被删除。因此，本文研究在不使用旧数据的情况下增量更新模型，并解决更新过程中可能出现的“灾难性遗忘”。

定义更新前的字典为旧字典 D_o ，更新后的字典为新字典 D_n 。 D_o 已使用属于历史工况的数据集 X_o 训练完成。 X_n 表示新工况的数据。参考增量学习的理念[34]，所提JMSDL方法使用 X_n 更新 D_o ，获得能够适应新工况数据 X_n 且不失去对旧数据 X_o 表征能力的新字典 D_n 。

JMSDL方法实现了多模态数据的表征，字典可以持续更新。因此，JMSDL的目标可分为两部分。第一部分称为模式匹配，即字典能够适应新工况数据。第二部分是保持字典对旧数据的表征能力并消除“灾难性遗忘”，称为相似性保持。JMSDL通过设计对应于两部分的约束项来建模，如图3所示。




图3. 模式匹配和相似性保持字典学习框架。框架包括用于学习新知识的重构项和用于通过保持模型更新前后相似性来消除对旧知识遗忘的保持项。

由于B是实对称矩阵，对B进行正交对角分解： $B = V\Lambda V^T$ ，其中V是对角矩阵且 $V^T V = I$ 。将式(8)代入式(7)得到 $D_n V\Lambda V^T = F$ ，进一步重写为 $D_n M V = F$ 。然后令 $D_n M = Q$ ， $F = P$ ，可重写为 $Q V = P$ 。

设 $[\mu_1, \mu_2, \dots, \mu_K]$ 为V的对角线元素组成的向量， q_{ij} 和 p_{ij} 分别为Q和P中的元素，根据式(11)得到 $q_{ij} \mu_j = p_{ij}$ ， i, j 。进一步可得到 q_{ij} 的求解公式： $q_{ij} = p_{ij} / \mu_j$ 。使用式(13)求解Q的每个元素，然后得到字典 D_n 的更新公式： $D_n = Q M^T$ 。

2) 更新W:

固定 D_n ，保留式(4)中与W相关的部分，得到子优化问题：

$$J_i = \|x_i - D_c w_i\|_2^2$$

使用OMP方法，可以直接求解式(15)的优化问题得到稀疏编码矩阵W。

步骤1)和2)依次迭代，直到达到迭代次数或满足收敛条件。虽然式(4)对于 (D_n, W) 不是联合凸的，但当其他变量固定时，对每个变量都是凸的。这样可以保证所设计优化方法的收敛性，收敛性在[14]和[36]中已有研究。

JMSDL优化算法的详细步骤总结在算法1中。

算法1 JMSDL方法

输入：新工况数据 X_n ，旧字典 D_o ，稀疏度T。

初始化： $D_n = D_o$ ，使用OMP方法获得初始W， $k = 0$ 。

当 $k < \text{迭代次数}$ 时

 步骤1：固定W， $B = W W^T$ ， $F = X_n W^T + (1/2) \lambda I D_o$ ；

 步骤2：根据式(8)分解B计算M和V；

 步骤3： $Q = D_n M$ ， $P = F M$ ；

 步骤4：对于 $i = 1$ 到 m ，对于 $j = 1$ 到 K ， $Q(i, j) = P(i, j) / V(j, j)$ ；

 步骤5： $D_n = Q M^T$ ；

 步骤6：对 D_n 的原子进行归一化， $d_i = d_i / \|d_i\|_2$ ， i ；

 步骤7：使用OMP方法获得W；

 步骤8： $k = k + 1$ ；

结束循环

输出：更新后的字典 D_n

使用JMSDL方法更新字典。在每次更新过程中，字典自适应地学习一个新工况。共采集了s个历史工况。对于第一个工况，使用K-SVD方法学习初始字典；对于剩余的s-1个工况，使用所提JMSDL方法依次更新字典s-1次，字典更新步骤如图4所示。

与传统的多模态方法相比，所提方法实现了模型的自适应更新，以适应实际工业过程中不断出现的新工况。此外，增量更新机制大大节省了训练资源。




图4.

字典更新步骤。首先，使用工况1的数据基于K-SVD方法获得D1；然后使用工况2的数据和D1基于所提JMSDL方法获得D2；然后使用工况3的数据和D2获得D3；然后使用工况4的数据和D3获得D4。一旦采集到新工况的数据，此字典更新过程可以继续。

B. 在线监测

在在线监测阶段，我们使用训练好的字典来监测工业过程的状态。模型中的其他变量（如W）不需要存储。具体来说，当在线数据到来时，我们使用字典重构数据，并根据重构误差的大小判断数据是正常还是故障。本节详细描述了控制限的计算，以及如何使用字典重构在线数据和如何判断数据状态。

1) 计算控制限：

学习所有历史工况数据后，获得当前字典 D_c 。使用 D_c 重构所有已学习的训练数据，并计算每个训练样本的重构误差： $R_i = \|x_i - D_c w_i\|_2^2$ ，其中 x_i 表示第 i 个训练样本， R_i 表示第 i 个样本的重构误差。 w_i 表示第 i 个样本的稀疏编码系数，可以使用OMP方法计算。计算所有训练样本的重构误差后，使用它们计算控制限 R_{tr} 。本文基于训练数据的重构误差，使用核密度估计（KDE）方法[37]计算 R_{tr} 。KDE方法的表达式为：

$$f(R) = \frac{1}{Mh} \sum_{i=1}^M K\left(\frac{|R - R_i|}{h}\right) \quad (17)$$

where M is the number of training samples and h denotes that can be automatically selected. $f(R)$ is the density function and $K(x)$ denotes the Gaussian kernel function.

$$w_{new} = \arg \min_w \|x_{new} - D_c w\|_2^2 \text{ s.t. } \|w\|_0 \leq T.$$

The above optimization problem can be solved using the OMP method. After obtaining the sparse coding, the reconstruction results for the online data can be obtained as follows:

$$\hat{x}_{new} = D_c w_{new}.$$

After that, we can calculate the reconstruction error of the online data as follows:

$$IRE_{new} = \|x_{new} - \hat{x}_{new}\|_2^2.$$

其中 M 表示训练样本数， h 表示可自动选择的带宽。 $f(R)$ 是密度函数， $K(x)$ 表示高斯核函数。使用KDE方法，选择适当的置信水平 α ，可以方便地获得控制限 R_{tr} 。

2) 在线数据监测：

当在线监测数据 x_{new} 到来时，我们不需要知道数据的工况标签，直接使用字典 D_c 重构数据，因为它对所有已学习的工况具有同等的表征能力。基于稀疏表示模型，稀疏编码计算如下：

$$IRE_{new} = \|x_{new} - \hat{x}_{new}\|_2^2.$$

Process monitoring is performed by calculating the reconstruction error of the online data. The dictionary has learned the training data, so it knows how to represent the online data if it is of the same class as the training data.

上述优化问题可以使用OMP方法求解。获得稀疏编码后，在线数据的重构结果为： $x_{new} = D_{cnew}w_{new}$ 。然后计算在线数据的重构误差： $IRE_{new} = ||x_{new} - D_{cnew}w_{new}||_2^2$ 。

通过计算在线数据的IRE进行过程监测。字典已学习了训练数据的特征，因此它知道如何表征这类数据。如果在线数据与用于训练的正常数据属于同一类，字典也能很好地重构它，其IRE将较小。故障数据与正常数据不同，字典不知道如何表征它，因此IRE较大。之前我们已使用训练数据的重构误差计算了控制限 R_{tr} 。因此，通过将 IRE_{new} 与控制限 R_{tr} 比较来判断当前数据是正常还是故障。如果 $IRE_{new} > R_{tr}$ ，我们认为当前在线数据存在故障。否则，数据是正常的。

综上所述，对于多模态过程，我们首先使用一个工况的数据通过K-SVD方法训练初始字典。然后基于初始字典，通过JMSDL方法更新字典，每次更新过程学习一个新工况的数据。最终获得对所有工况数据具有表征能力的字典。基于训练数据的重构误差计算控制限。在在线监测阶段，计算在线数据的重构误差并与控制限比较，判断数据是否存在故障。

III. 实验结果与分析

本节介绍数值仿真实验和CSTH仿真实验，以说明所提JMSDL方法的优越性。首先定义一些指标来量化所提方法的优越性。

为定量评估旧字典与更新后字典之间的相似性，定义字典相似度 d_s ：
$$d_s = \frac{1}{K} \sum_{i=1}^K |d_{oi} - d_{ni}|$$
，其中 K 表示字典中的原子数， d_{oi} 表示旧字典的第 i 个原子， d_{ni} 表示更新后字典的第 i 个原子。 d_s 是0到1范围内的值，值越接近1，两个字典越相似。

为定量评估字典对各工况数据的表征能力，定义平均重构误差MRE：
$$MRE = \frac{1}{m} \sum_{i=1}^m IRE_i$$
，其中 IRE_i 表示第 i 个样本的重构误差， m 表示样本数。MRE越小，字典对该工况的重构能力越好。

为定量评估各种过程监测方法的有效性，定义故障检测率（FDR）和误报率（FAR）：
$$FDR = \frac{tp}{故障数据总数} \times 100\%, FAR = \frac{fp}{正常数据总数} \times 100\%$$
，其中 tp 表示正确检测到的故障样本数， fp 表示被错误分类为故障的正常样本数。

为展示我们方法的优越性，选择了四种最先进的过程监测方法进行比较，包括PCA混合模型（mPCA）方法[29]、传统字典学习（DL）方法[14]、LCDL方法[30]和ODL方法[32]。DL方法作为最典型的字典学习方法参与比较。我们希望将所提方法与多模态过程监测的全局建模方法进行比较，因此选择LCDL方法。此外，PCA是一种重要的过程监测方法，我们选择了先进的多模态PCA方法——mPCA。我们还选择了ODL方法，这是一种先进的在线更新方法。它与所提方法有许多共同点，两者都能持续学习新知识。但与ODL不同的是，所提JMSDL方法考虑了模型在学习新知识时不遗忘旧知识。我们用保持项实现了这一功能，而ODL中没有这一功能。

A. 数值仿真

设计了一个多模态数据生成系统来测试所提方法在多模态过程数据上的性能。由于多模态数据要求不同工况的数据呈现不同分布，我们按以下方式生成数据： $x = A_i s + e$ ，其中 $A_i \in R^{(20 \times 2)}$ 是随机观测矩阵，不同工况使用不同的 A_i 。 $s = [s_1, s_2]^T$ 表示过程的状态向量，本实验中 $s_1 \sim N(2, 1)$ ， $s_2 \sim N(3, 1)$ 。 $e = [e_1, e_2, \dots, e_{20}]^T$ 表示高斯噪声， $e_i \sim N(0, 0.1)$ 。 $x = [x_1, x_2, \dots, x_{20}]^T$ 表示模拟过程数据。

一般来说，当观测矩阵变化时，由式(26)生成的数据分布也会变化，数据将被划分为不同工况。因此，我们使用不同的随机矩阵 A_i 来获得不同工况的数据。由于状态向量 s 服从正态分布，每次使用式(26)时 s 都不同，确保我们可以为每个工况生成大量不同样本。因此，上述数值仿真系统生成的数据完全满足本实验的要求。

首先，使用数值仿真系统验证优化算法的可行性。由于 λ_1 是一个重要参数，我们对 λ_1 进行了敏感性分析实验。改变 λ_1 ，运行优化算法获得更新后的字典，计算当前 λ_1 对应的 d_s 。为消除随机初始化引起的波动，我们进行了多次相同实验并计算 d_s 的均值和标准差。得到如图5所示的曲线。

图5的结果表明，当 λ_1 增大时， d_s 总体上趋于增大，其标准差趋于减小。即 λ_1 的增大促进了新字典与旧字典更加相似，这与式(4)的优化问题一致。此外，为更直观地展示旧字典与新字典的相似性，我们对矩阵 $(D_o - D_n)$ 进行了可视化，如图6所示。矩阵中大多数元素的值接近0，只有少数列中的一些元素值较大。由于 $(D_o - D_n)$ 反映了两个字典之间的差异，图6表明两个字典的大多数对应原子非常相似，只有少数不同，如第11和第80个原子。这表明字典更新

后新知识被写入了这些少数原子中。变化不大的原子保持了它们之前学到的知识。

实际上，并不是更新后的模型与之前的越相似，监测效果就越好。因为这反映了模型没有学习新知识。因此，需要调整 λ_1 找到一个合适的区间，使模型既能学习新知识又不遗忘旧知识。图5和图6的实验结果说明了所提优化算法是可行的，能使更新后的字典与旧字典相似。




图5. 不同 λ_1 对 ds 的影响。 λ_1 的增大促进了新字典与旧字典更加相似。




图6. $(D_o - D_n)$ 的热力图。字典更新时，少数原子被重写，这表示新知识，而大多数未变化的原子用于保持旧知识。

验证优化算法的可行性后，使用数值仿真数据检验JMSDL方法表征多模态数据的能力。本实验过程可分为三个步骤：

1) 数据生成：使用式 (26) 生成训练数据和测试数据。本实验使用四个不同的随机矩阵A1到A4生成共四个工况的数据。每个工况有1000个样本作为训练数据，250个样本作为测试数据。总共有4000个训练样本和1000个测试样本。在测试数据集中，数据按工况1、工况2、工况3和工况4的顺序排列。

2) 模型训练：模型训练和更新步骤如图4所示。首先，使用工况1的数据基于式 (2) 获得D1；然后使用工况2的数据和D1基于式 (4) 获得D2；然后使用工况3的数据和D2获得D3；然后使用工况4的数据和D3获得D4。

3) 数据表征：分别获得D1到D4后，使用四个字典表征测试数据集。对于每个字典，通过式 (19) 获得测试数据的稀疏编码，然后通过式 (21) 计算IRE。然后通过式 (23) 计算字典对每个工况的平均重构误差MRE，以评估字典对不同工况数据的表征能力。

字典大小和 λ 1 是两个重要的超参数。我们使用少量数据作为验证集后，使用网格搜索找到最优参数组合。稀疏度通常应小于字典大小的10%。实验参数设置如下：每个字典大小相同，字典原子数为80。工况1的稀疏度为3。使用JMSDL方法获得D2时， λ 1 为3，稀疏度为3。训练D3时， λ 1 为2.5，稀疏度为3。训练D4时， λ 1 为2.6，稀疏度为5。

为验证保持项在JMSDL方法中的作用，进行了数据表征对比实验。当移除保持项时，JMSDL方法退化为传统字典学习。因此，我们比较了JMSDL和DL方法在连续学习四个工况时对测试数据的性能，如图7所示。可以看出DL面临严重的灾难性遗忘，每当完成一个工况数据的学习后，它往往忘记如何表征之前的工况，导致重构误差增大。相比之下，带有保持项的JMSDL方法具有更好的持续学习能力。

9




图7. 不同字典对数值仿真测试数据表征效果的比较。(a)–(d) 传统DL方法连续学习四个工况时测试数据上的DRE统计。(e)–(h) 所提JMSDL方法连续学习四个工况时测试数据上的IRE统计。所提方法避免了传统字典学习面临的“灾难性遗忘”问题。




图8. 四个字典对数值仿真数据四个工况的平均重构误差。MRE越小，对该工况的表征越好。JMSDL能持续学习新工况并保持对之前工况的小MRE。

更直观地，我们展示了JMSDL获得的四个字典对四个工况的MRE指标，如图8所示。D1只能表征工况1，因为它只学习了如何表征工况1的数据，对其他工况有较大的重构误差。基于D1，使用工况2的训练数据将字典更新为D2。D2可以表征工况1和2。同样，D3可以表征工况1、2和3；D4可以表征所有四个工况。此外，当一个工况未被学习时，重构误差非常大。这有两个原因：一是字典尚未学习如何表征该工况；二是数值仿真数据的维度和数据值本身偏大。

通过数据表征实验，我们发现JMSDL方法每次更新时都能学习新工况的数据。更新后的字典对历史工况也具有好的表征能力，这就是保持项的作用。JMSDL方法不会出现“灾难性遗忘”。

接下来，对JMSDL方法和比较方法进行过程监测实验。由于D4可以表征所有工况的数据，使用D4对该多模态数值仿真过程进行过程监测。过程监测实验同样可分为三个步骤：数据生成、模型训练和在线监测。

在过程监测实验中，训练数据集保持不变。对于测试数据集，在每个工况的最后125个数据中对x2添加+4偏置故障。因此，测试数据中有500个正常样本和500个故障样本。

在模型训练步骤中，除了获得D4外，还需要计算控制限。应计算D4对所有训练样本的重构误差，然后使用KDE方法计算控制限 R_{tr} 。在在线监测步骤中，使用OMP方法获得D4对每个测试数据的稀疏编码，然后计算重构误差IRE。将IRE与 R_{tr} 比较以判断在线数据是否存在故障。

使用mPCA、DL、LCDL和ODL方法作为比较方法。对于四种比较方法，使用所有工况的训练数据训练模型，然后对测试数据进行过程监测。通过比较FAR和FDR判断不同方法的过程监测效果。各方法参数设置如下：mPCA方法的CPV为0.85。所有基于DL的方法，原子数为80，稀疏度为3。所有方法的置信水平为0.99。




图9. 不同方法对数值仿真数据的过程监测效果。(a) mPCA方法的 nT^2 统计量。(b) mPCA方法的 $nSPE$ 统计量。(c) DL方法的DRE统计量。(d) LCDL方法的DRR统计量。(e) ODL方法的OLRE统计量。(f) 所提JMSDL方法的IRE统计量。

图9显示了不同方法对数值仿真数据的过程监测效果。虽然mPCA是一种多模态方法，但它也面临统计平均问题，导致对某些工况失效。DL是单模态方法，在处理多模态数据时效果不佳。LCDL是一种全局建模方法，使用一个字典表征所有工况的数据。在本实验中发现，LCDL方法对工况1、3和4具有相同水平的重构误差，但对工况2的重构误差较大，这导致控制限过大，FDR很低。

ODL方法在监测数值仿真数据时被发现有几个缺点。首先，ODL方法在在线学习测试数据时可能将故障数据学习为正常数据，导致更新后的模型无法区分故障。其次，虽然在初始建模阶段学习了所有工况的数据，但随着模型的更新，模型出现“灾难性遗忘”，导致新工况出现时重构误差特别大，只有在线学习一些新工况数据后才能降低重构误差。

所提方法对每个工况的正常数据具有较小的重构误差，对故障数据具有较大的重构误差。此外，不同工况的重构误差保持在同一范围内。因此，所提方法能很好地区分正常数据和故障数据，具有良好的过程监测效果。

B. CSTD仿真实验

CSTD过程是一个广泛使用的工业过程基准。CSTD过程的示意图如图10所示。在本实验中，我们使用CSTD仿真系统生成三个工况。这些工况的详细参数设置见表I。

对于每个工况，有1000个正常样本作为训练数据，250个正常样本作为测试数据。首先，使用K-SVD方法训练工况1的数据获得D1，原子数为80，稀疏度为4。然后，基于JMSDL方法使用工况2的数据将字典更新为D2，稀疏度为4， λ_1 为0.05。基于JMSDL方法使用工况3的数据将字典从D2更新为D3，稀疏度为4， λ_1 为0.28。




图10. CSTD过程示意图。

表I 三种工况的参数设置

工况	参数1	参数2	参数3
工况1	设定值1A	设定值1B	设定值1C
工况2	设定值2A	设定值2B	设定值2C
工况3	设定值3A	设定值3B	设定值3C

使用这三个字典表征测试数据，图11显示了表征效果。D1只能表征工况1；D2可以表征工况1和工况2；D3可以表征所有三个工况。为定量展示字典对各工况的表征效果，计算了三个字典对每个工况的MRE，如表II所示。

每次用新工况更新字典都会降低该工况的重构误差，同时保持字典对之前学习过的工况的表征能力，使所有工况的重构误差保持在同一水平。该实验验证了JMSDL方法能够在不出现“灾难性遗忘”的情况下适应新工况。




图11. 不同字典对CSTH过程测试数据的表征效果。(a) D1对测试数据的IRE。(b) D2对测试数据的IRE。(c) D3对测试数据的IRE。JMSDL能持续学习CSTH的多模态数据而不出现“灾难性遗忘”。

表II 三个字典对CSTH过程各工况的MRE统计

字典	工况1 MRE	工况2 MRE	工况3 MRE
D1	小	大	大
D2	小	小	大
D3	小	小	小

接下来，使用D3监测CSTH过程。为验证方法监测故障的能力，在测试数据中添加了故障数据。设置了三种故障情况，分别发生在这三个工况中，如表III所示。每个工况的测试数据中添加250个故障样本，测试数据共有1500个样本，包含来自三个工况的750个正常数据和750个故障数据。

比较方法的参数设置如下：mPCA方法的CPV为0.85。所有基于DL的方法，原子数为80，稀疏度为4。所有方法的置信水平为0.99。

表III CSTH过程中三种工况的三种故障情况

故障编号	工况	故障类型	故障变量
故障1	工况1	偏置故障	液位
故障2	工况2	乘性故障	温度
故障3	工况3	乘性故障	流量




图12. 不同方法对CSTH过程数据的过程监测效果。(a) mPCA方法的nT2统计量。(b) mPCA方法的nSPE统计量。(c) DL方法的DRE统计量。(d) LCDL方法的DRR统计量。(e) ODL方法的OLRE统计量。(f) 所提JMSDL方法的IRE统计量。

图12显示了各方法对CSTH过程的监测效果。mPCA方法只能检测温度上的乘性故障；DL方法无法检测液位上的偏置故障；LCDL方法无法检测流量上的乘性故障；ODL方法对新工况数据有较大的重构误差，只有在线学习该工况的一些测试数据后才能降低。这些方法的缺陷导致较大的FAR或较小的FDR。所提JMSDL方法对每个工况的正常数据具有相同的表征能力，因此定量来看，JMSDL方法对CSTH过程具有最佳的监测效果。

参考文献

- [1] J. Liu et al., "Toward robust fault identification of complex industrial processes using stacked sparse-denoising autoencoder with Softmax classifier," *IEEE Trans. Cybern.*, 2021.
- [2] W. Yu, C. Zhao, and B. Huang, "MoniNet with concurrent analytics of temporal and spatial information for fault detection in industrial processes," *IEEE Trans. Cybern.*, 2021.
- [3] J. Yu and X. Yan, "Whole process monitoring based on unstable neuron output information in hidden layers of deep belief network," *IEEE Trans. Cybern.*, vol. 50, no. 9, pp. 3998–4007, Sep. 2020.
- [4] J. Zhang, H. Chen, S. Chen, and X. Hong, "An improved mixture of probabilistic PCA for nonlinear data-driven process monitoring," *IEEE Trans. Cybern.*, vol. 49, no. 1, pp. 198–210, Jan. 2019.
- [5] P. Goodall, D. Pantazis, and A. West, "A cyber physical system for tool condition monitoring using electrical power and a mechanistic model," *Comput. Ind.*, vol. 118, Jun. 2020.
- [6] D. Gorinevsky, "Fault isolation in data-driven multivariate process monitoring," *IEEE Trans. Control Syst. Technol.*, vol. 23, no. 5, pp. 1840–1852, Sep. 2015.
- [7] J. Jiang and Q. Jiang, "Variational Bayesian probabilistic modeling framework for data-driven distributed process monitoring," *Control Eng. Pract.*, vol. 110, May 2021.
- [8] W. Li, H. H. Yue, S. Valle-Cervantes, and S. J. Qin, "Recursive PCA for adaptive process monitoring," *J. Process Control*, vol. 10, no. 5, pp. 471–486, 2000.
- [9] S. Yin, G. Wang, and H. Gao, "Data-driven process monitoring based on modified orthogonal projections to latent structures," *IEEE Trans. Control Syst. Technol.*, vol. 24, no. 4, pp. 1480–1487, Jul. 2016.
- [10] R. Guo and N. Zhang, "A process monitoring scheme for uneven-duration batch process based on sequential moving principal component analysis," *IEEE Trans. Control Syst. Technol.*, vol. 28, no. 2, pp. 583–592, Mar. 2020.
- [11] K. Huang, S. Wu, F. Li, C. Yang, and W. Gui, "Fault diagnosis of hydraulic systems based on deep learning model with multirate data samples," *IEEE Trans. Neural Netw. Learn. Syst.*, 2021.
- [12] G. Chen and Z. Ge, "SVM-tree and SVM-forest algorithms for imbalanced fault classification in industrial processes," *IFAC J. Syst. Control*, vol. 8, Jun. 2019.
- [13] Q. Jiang, X. Yan, and B. Huang, "Neighborhood variational Bayesian multivariate analysis for distributed process monitoring with missing data," *IEEE Trans. Control Syst. Technol.*, vol. 27, no. 6, pp. 2330–2339, Nov. 2019.
- [14] M. Aharon, M. Elad, and A. Bruckstein, "K-SVD: An algorithm for designing overcomplete dictionaries for sparse representation," *IEEE Trans. Signal Process.*, vol. 54, no. 11, pp. 4311–4322, Nov. 2006.
- [15] Z. Jiang, Z. Lin, and L. Davis, "Label consistent K-SVD: Learning a discriminative dictionary for recognition," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 35, no. 11, pp. 2651–2664, Nov. 2013.
- [16] J. Mairal, F. Bach, J. Ponce, G. Sapiro, and A. Zisserman, "Supervised dictionary learning," *Advances in Neural Information Processing Systems*, vol. 21, 2008.
- [17] Q. Zhang and B. Li, "Discriminative K-SVD for dictionary learning in face recognition," in *Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit.*, 2010, pp. 2691–2698.
- [18] K. Huang, Z. Tao, B. Sun, C. Yang, and W. Gui, "Industrial process modeling and monitoring based on jointly specific and shared dictionary learning," *IEEE Trans. Instrum. Meas.*, vol. 71, pp. 1–11, Nov. 2021.
- [19] K. Huang, L. Zhang, B. Sun, X. Liang, C. Yang, and W. Gui, "A latent feature oriented dictionary learning method for closed-loop process monitoring," *ISA Trans.*, to be published.
- [20] X. Peng, Y. Tang, W. Du, and F. Qian, "Multimode process monitoring and fault detection: A sparse modeling and dictionary learning method," *IEEE Trans. Ind. Electron.*, vol. 64, no. 6, pp. 4866–4875, Jun. 2017.
- [21] K. Huang, Y. Wu, H. Wen, Y. Liu, C. Yang, and W. Gui, "Distributed dictionary learning for high-dimensional process monitoring," *Control Eng. Pract.*, vol. 98, May 2020.
- [22] K. Huang, H. Wen, H. Ji, L. Cen, X. Chen, and C. Yang, "Nonlinear process monitoring using kernel dictionary learning with application to aluminum electrolysis process," *Control Eng. Pract.*, vol. 89, pp. 94–102, Aug. 2019.
- [23] H. Ma, Y. Hu, and H. Shi, "A novel local neighborhood standardization strategy and its application in fault detection of multimode processes," *Chemometr. Intell. Lab. Syst.*, vol. 118, pp. 287–300, Aug. 2012.
- [24] C. Tong, A. Palazoglu, and X. Yan, "An adaptive multimode process monitoring strategy based on mode clustering

and mode unfolding," J. Process Control, vol. 23, no. 10, pp. 1497–1507, 2013.

[25] S. Zhao, J. Zhang, and Y. Xu, "Monitoring of processes with multiple operating modes through multiple principle component analysis models," Ind. Eng. Chem. Res., vol. 43, no. 22, pp. 7025–7035, 2004.

[26] S. Natarajan and R. Srinivasan, "Multi-model based process condition monitoring of offshore oil and gas production process," Chem. Eng. Res. Design, vol. 88, nos. 5–6, pp. 572–591, 2010.

[27] C. Zhao, F. Wang, Z. Mao, N. Lu, and M. Jia, "Improved batch process monitoring and quality prediction based on multiphase statistical analysis," Ind. Eng. Chem. Res., vol. 47, no. 3, pp. 835–849, 2008.

[28] D. Hwang and C. Han, "Real-time monitoring for a process with multiple operating modes," Control Eng. Pract., vol. 7, no. 8, pp. 891–902, 1999.

[29] X. Xu, L. Xie, and S. Wang, "Multimode process monitoring with PCA mixture model," Comput. Elect. Eng., vol. 40, no. 7, pp. 2101–2112, 2014.

[30] C. Ning, M. Chen, and D. Zhou, "Sparse contribution plot for fault diagnosis of multimodal chemical processes," IFAC-PapersOnLine, vol. 48, no. 21, pp. 619–626, 2015.

[31] J. C. Jeng, "Adaptive process monitoring using efficient recursive PCA and moving window PCA algorithms," J. Taiwan Inst. Chem. Eng., vol. 41, no. 4, pp. 475–481, 2010.

[32] K. Huang, Y. Wu, C. Long, H. Ji, and C. Yang, "Adaptive process monitoring via online dictionary learning and its industrial application," ISA Trans., vol. 114, pp. 399–412, Aug. 2021.

[33] S. Sahoo and A. Makur, "Signal recovery from random measurements via extended orthogonal matching pursuit," IEEE Trans. Signal Process., vol. 63, no. 10, pp. 2572–2581, May 2015.

[34] C. Giraud-Christophe, "A note on the utility of incremental learning," AI Commun., vol. 13, no. 4, pp. 215–223, 2000.

[35] K. Huang, Y. Wu, C. Wang, Y. Xie, and W. Gui, "A projective and discriminative dictionary learning for high-dimensional process monitoring with industrial applications," IEEE Trans. Ind. Informat., vol. 17, no. 1, pp. 558–568, Jan. 2021.

[36] J. Mairal, F. Bach, J. Ponce, and G. Sapiro, "Online dictionary learning for sparse coding," in Proc. 26th Annu. Int. Conf. Mach. Learn., 2009, pp. 689–696.

[37] Z. Ge and Z. Song, "Process monitoring based on independent component analysis–Principal component analysis (ICA-PCA) and similarity factors," Ind. Eng. Chem. Res., vol. 46, no. 7, pp. 2054–2063, 2007.

作者简介

Keke Huang

2012年获得东北大学自动控制学士学位，2017年获得清华大学控制科学与工程博士学位。2017年4月至2021年9月任中南大学副教授，现为中南大学自动化学院教授。研究方向包括工业大数据、过程监测与控制、网络科学。

Zui Tao

2021年获得中南大学自动化学士学位，现于中南大学攻读控制科学与工程硕士学位。研究方向包括字典学习和过程监测。

Yishun Liu

2017年获得中南大学自动控制学士学位，现于中南大学攻读控制科学与工程博士学位。研究方向包括过程监测、机器学习和供应链优化。

Bei Sun

2015年获得中南大学控制科学与工程博士学位。2012年至2014年在纽约大学理工学院电气与计算机工程系工作。现为中南大学副教授。研究方向包括数据驱动建模、有色金属冶金过程的优化和控制。

Chunhua Yang

1988年和2002年分别获得中南大学自动控制工程硕士学位和控制科学与工程博士学位。1999年起任中南大学信息科学与工程学院教授，现为自动化学院院长。研究方向包括复杂工业过程的建模与最优控制、智能控制系统。

Weihua Gui

1976年和1981年分别获得中南大学电气工程学士学位和自动控制工程硕士学位。2013年起任中国工程院院士，现任职于中南大学自动化学院。研究方向包括复杂工业过程的建模与最优控制、故障诊断、分布式鲁棒控制。

Shiyan Hu

2008年获得德州农工大学金斯维尔分校计算机工程博士学位。现任南安普顿大学网络物理系统安全教授兼主席。研究方向包括网络物理系统和网络物理系统安全，已发表150余篇论文，其中60余篇发表在IEEE Transactions上。现任IEEE网络物理系统技术委员会主席，IET Cyber-Physical Systems主编。