

基于稀疏贡献图的多模态化工过程故障诊断

Chao Ning, Maoyin Chen, Donghua Zhou

IFAC-PapersOnLine 48-21 (2015) 619 – 626

摘要:

化工过程通常在不同操作模式下运行, 以满足市场需求并实现更高利润。这 necessitates 研究多模态化工过程的相关算法和报警系统。尽管在多模态过程监测方面已有一定的研究投入, 但在处理多种模式时, 故障诊断问题却很少受到关注。本文提出了一种基于标签一致性字典学习 (LCDL) 的多模态过程监测方法和用于故障诊断的稀疏贡献图 (SpCP)。首先, 通过标签一致性 K-SVD 算法从正常历史过程数据中获取判别性和重建性字典。此外, 我们将学习到的字典进行扩充, 得到另一个字典, 该字典由两个块组成, 一个用于多种正常操作模式, 另一个用于故障。然后, 在在线监测期间, 使用上述扩充字典对新样本进行稀疏编码。之后, 计算其字典重建残差 (DRR) 用于故障检测。最后, 提出了一种新的稀疏贡献图来找出检测到的故障的根本原因。SpCP 能够更好地突出真正的原因而没有歧义, 因为只有少量变量的稀疏贡献是非零的。通过数值仿真和连续搅拌槽加热器 (CSTH) 过程验证了所提方法的有效性。

关键词: 多模态; 过程监测; 故障诊断; 稀疏表示; 字典学习; 稀疏贡献图

1. 引言

在大数据时代, 越来越多的化工厂开始充分利用大量在线测量数据来监测工厂的健康状况。过程监测技术已被广泛采用, 以确保安全运行并防止重大经济损失。

多变量统计过程监测 (MSPM) 技术, 包括主成分分析 (PCA) 和偏最小二乘 (PLS) 等典型方法, 已在许多研究文献中报道并在实际应用中取得了成功 (MacGregor and Kourti [1995]; Qin [2003]; Wise and Gallagher [1996]; Tong and Crowe [1995])。由于化工过程的复杂性, 对传统 MSPM 技术进行了一些改进 (Cheng et al. [2010]; Ge and Song [2007]; Zhou et al. [2010])。然而, 确定异常的发生只是一个好的开始, 这并不是故事的结束。更具体地说, 操作人员需要找出检测到的故障的原因, 这是故障诊断或故障隔离的主要目标, 以使过程恢复正常状态。为了解决这个问题, 文献中提出了贡献图 (Miller et al. [1998])。贡献图的一大优势是它们不需要假设任何关于故障的先验知识。

基于重建的贡献 (RBC) 被提出并取得了比传统贡献图更好的结果 (Alcala and Qin [2009])。RBC 的主要局限性在于它假设了故障方向或故障子空间, 这在许多情况下并不成立。其他工作采用相似性因子来诊断故障 (Raich and Cinar [1996]; Yoon and MacGregor [2001]; Kano et al. [2002]; Singhal and Seborg [2002])。虽然传统的故障检测和诊断方法已经得到了很好的研究, 但值得注意的是它们没有考虑多种操作模式, 这是一种经常遇到的现象 (Hwang and Han [1999])。

为了监测多模态过程, 研究人员提出了很多方法。其中一类方法被称为「基于模型库的方法」(Ge et al. [2013]), 对每种操作模式分别建模。例如, 提出的 Mix-PCA、多 PCA 和多 PLS (Chen and Liu [1999]; Zhao et al. [2004]; Zhao et al. [2006]) 属于此类。最近, 提出了基于隐马尔可夫模型的统计模式分析 (HMM-SPA), 用于使用索引切换方案的多模态过程监测 (Ning et al. [2014])。还存在另一类方法, 采用贝叶斯框架内的组合策略。例如, 提出了有限高斯混合模型 (FGMM) 和基于贝叶斯推理的高斯混合贡献 (BIGMC) 方法 (Yu and Qin [2008]; Yu [2013])。在文献中开发了 PPCA 的混合贝叶斯正则化方法 (Ge and Song [2010])。虽然有大量研究文献涉及多模态过程的故障检测, 但在找出检测到的故障的原因方面很少受到关注。

2. 基于稀疏表示的多模态过程故障检测与诊断

2.1 离线建模: LCDL 算法

在本节中, 我们要介绍离线建模过程, 其中从历史过程数据集中学习判别性和重建性字典。过程在多种模式下运行, 从不同模式生成的样本具有不同的标签。因此, 判别性字典适合表征多模态过程数据的本质。此外, 重建误差通常用于检测异常, 因此使学习到的字典具有强大的重建能力变得必要。基于上述两点观察, 标签一致性字典更适合多模态化工过程的故障检测。

假设有 C 种操作模式, $X = [X_1, \dots, X_2, \dots, X_C] \in \mathbb{R}^{n \times m}$ 表示正常过程数据集, 其中 $X_i \in \mathbb{R}^{n \times m_i}$ 是从第 i

种模式收集的数据集，包含 m 个传感器和 N 个样本。正常样本总数为 $N = \sum N$ 。整体数据集 X 的每一列都有一个标签，即该列所属的操作模式。定义字典学习的目标函数如下（Jiang et al. [2013]）：

$$\begin{aligned} \argmin \quad & \|X - DA\|_F + \lambda \|Q - UA\|_F + \beta \|L - WA\|_F \\ \text{s.t.} \quad & \|a\| \leq n \end{aligned}$$

其中 $D = [d_1, d_2, \dots, d_C] \in \mathbb{R}^{m \times C}$ 是学习到的字典， $A = [a_1, a_2, \dots, a_N] \in \mathbb{R}^{C \times N}$ 是训练数据 X 的稀疏编码， $L = [l_1, l_2, \dots, l_N] \in \mathbb{R}^{1 \times N}$ 是训练数据 X 的标签。如果训练样本 x 从第 j 种操作模式生成，则 $l = [0, 0, \dots, 1, \dots, 0, 0]$ ，其中只有第 j 个元素为 1。 $Q = [q_1, q_2, \dots, q_N] \in \mathbb{R}^{1 \times N}$ 是训练数据的判别性稀疏编码。如果第 i 个训练样本 x 和第 j 个字典原子 d 具有相同的标签，则矩阵 Q 的第 i 行第 j 列的元素为 1，否则为 0。 $U \in \mathbb{R}^{1 \times C}$ 和 $W \in \mathbb{R}^{1 \times C}$ 都是线性变换。

为了简化，目标函数可以重写为（Jiang et al. [2013]）：

$$\begin{aligned} \argmin \quad & \|X; \sqrt{\lambda} Q; \sqrt{\beta} L\|_F - \|D; \sqrt{\lambda} U; \sqrt{\beta} W\|_F \\ \text{s.t.} \quad & \|a\| \leq n \end{aligned}$$

标签一致性 K-SVD 算法用于求解上述优化问题。标签一致性 K-SVD 的详细描述可以在文献（Jiang et al. [2013]）中找到。

2.2 在线监测方案

受文献（Wright et al. [2009]）的启发，作者提出扩充原始字典以解决人脸识别中的部分遮挡或损坏问题，我们尝试以同样的方式处理过程异常。此外，扩充字典有助于故障诊断，这将在下一小节中详细阐述。当发生某种过程异常时，传感器数据可以表示如下（Wright et al. [2009]）：

$$x = Da + f = [D \ I] \begin{bmatrix} a; f \end{bmatrix}$$

其中 f 被假定具有少量非零项。扩充字典定义如下：

$$D = [D \ D_{C+1}]$$

其中 $D = [D_1, D_2, \dots, D_C]$ 由 C 个子字典组成， $D_i \in \mathbb{R}^{m \times C_i}$ 对应第 i 种操作模式。 D_{C+1} 是单位矩阵。从上述公式中，我们观察到扩充字典 D 有两个块，即 D 和 D_{C+1} ，分别对应正常操作模式和故障。为了简洁起见，我们采用与文献（Wang and Kong [2014]）相同的选择算子。选择算子表示为 $P = [p_1, p_2, \dots, p_C, p_{C+1}] \in \mathbb{R}^{(C+1) \times (C+1)}$ 。

在线过程监测期间，新样本 x_{new} 通过以下方式稀疏编码：

$$a_{\text{new}} = \argmin \|Da - x_{\text{new}}\| \quad \text{s.t.} \quad \|a\| \leq n$$

类似于文献（Ren and Lv [2014]），我们计算新样本的字典重建残差（DRR）如下：

$$\text{DRR} = \|x_{\text{new}} - DPP a_{\text{new}}\|$$

其中 $P = [P_1, P_2, \dots, P_C]$ 。将其 DRR 与 DRR_{th} 的阈值进行比较，以确定过程是正常还是异常。 DRR_{th} 的阈值可以从训练数据中以经验方式获得。

所提的基于 LCDL 的多模态过程监测方法通过给出以下示意图进行总结（图 1）。

2.3 基于稀疏贡献图的故障诊断方法

在本节中，提出了稀疏贡献图（SpCP）来执行多模态过程的故障诊断。一旦检测到故障，工厂人员需要知道故障的可能原因。如上所述，扩充字典使得执行故障诊断任务变得容易，因为新样本对应扩充字典第二块的稀疏编码反映了严重的故障变量。

第 i 个变量对过程异常的稀疏贡献定义如下：

$$\text{SpC}(i) = [\mathbf{eP}_{\{C+1\}} \alpha_{\text{new}}] / \sum [\mathbf{eP}_{\{C+1\}} \alpha_{\text{new}}]$$

其中 $\mathbf{e} = [0, \dots, 0 \text{ (} i-1 \text{个)}, 1, 0, \dots, 0 \text{ (} m-i \text{个)}]$ 。在计算每个贡献后，可以基于这些贡献轻松获得 SpCP 。

正交匹配追踪 (OMP) 算法 (Eldar and Kutyniok [2012]; Elad [2010]) 对稀疏编码至关重要。为了完整地描述基于稀疏贡献图的故障诊断方法，本节给出了 OMP 算法的更详细描述。我们向读者推荐两本关于稀疏表示和压缩感知的专著 (Eldar and Kutyniok [2012]; Elad [2010])。OMP 算法的步骤总结如下 (Eldar and Kutyniok [2012])：

Step 1: 初始化 $\alpha = 0$, $\mathbf{r} = \mathbf{x}$, $\Gamma = \emptyset$ 且 $i = 0$;
 Step 2: $i := i + 1$;
 Step 3: $\mathbf{g} \leftarrow [\mathbf{D}\mathbf{r}] / \|\mathbf{r}\|$;
 Step 4: $j \leftarrow \text{argmin}|\mathbf{g}|$, $\Gamma \leftarrow \Gamma \cup \{j\}$;
 Step 5: $\alpha_{\{\Gamma\}} \leftarrow \mathbf{D}_{\{\Gamma\}}^{\dagger} \mathbf{x}$, $\alpha_{\setminus\{\Gamma\}} \leftarrow 0$;
 Step 6: $\mathbf{r} = \mathbf{x} - \mathbf{D}\alpha$;
 Step 7: 如果 $i < n$, 跳转到 Step 2, 否则执行 Step 8;
 Step 8: $\alpha \leftarrow \alpha$;
 Step 9: 输出稀疏编码 α 。

符号 i 用作迭代次数, Γ 是 α 在第 i 次迭代时的支持集。值得注意的是, 按照惯例, 字典的列已被归一化。考虑到这一惯例, 我们可以清楚地看到 Step 3 的目的是计算 $\mathbf{x}$ 与字典原子之间的相关系数。在 OMP 算法中, 选择 $\mathbf{x}$ 为故障数据或一段故障数据的均值 (Yu [2013]), 以便使用稀疏贡献图。表示矩阵的伪逆。

3. 示例验证

3.1 数值仿真

使用一个多变量系统来验证所提故障检测和诊断方法的有效性和优越性。线性系统如下所示 (Ge and Song [2009])：

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} 0.5768 & 0.3766 & 0.7382 & 0.0566 & 0.8291 & 0.4009 & 0.6519 & 0.2070 & 0.3972 & 0.8045 \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \\ e_5 \end{bmatrix}$$

其中 $\mathbf{s} = [s_1 \ s_2]$ 表示两个独立源, $\mathbf{e} = [e_1 \ e_2 \ e_3 \ e_4 \ e_5]$ 表示噪声向量, 由五个独立的零均值高斯噪声组成, 标准差为 0.1。有三种操作模式, 相关源如下：

模式 1: $s(k) : N(-10, 1)$; $s(k) : N(-5, 1)$
 模式 2: $s(k) = 0.1\cos(0.08k)\sin(0.006k)$; $s(k) = 4\text{sign}[\sin(0.03k) + 9\cos(0.01k)]$
 模式 3: $s(k) : \text{Uniform}(2, 3)$; $s(k) : N(7, 1)$

训练数据由从三种操作模式收集的 6000 个样本组成。它们用于通过 LC-KSVD 算法训练标签一致性字典。创建了表 1 中的以下测试用例来验证所提故障检测和诊断方法的实用性和优越性。

在 Case 1 中, 系统最初在模式 1 运行 100 个样本, 然后切换到模式 2。在第 201 个样本处引入乘法故障, 使 x 的测量值降低 30%。从图 2 可以看出, PCA 混合模型 (Xu et al. [2011]) 无法提供令人满意的监测结果, 然而, FGMM (Yu and Qin [2008]) 和基于 LCDL 的方法都能检测到乘法故障。从表 2 可以看出, 基于 LCDL 的方法的故障检测率高于 FGMM。图 3 展示了传统贡献图、BIGMC 索引图 (Yu [2013]) 和所提稀疏贡献图 (SpCP) 的故障诊断结果。

从图 3(a) 和 (b) 可以看出, T 贡献图和 SPE 贡献图都表明 x 的测量值受到严重污染。不幸的是, 传统贡献图隔离了错误的故障变量。虽然 BIGMC 索引图找出了真正的故障变量 x , 但由于 x 的贡献不可忽略, 它可能会使过程人员感到困惑。与其他两种方法相比, 稀疏贡献图在没有任何歧义的情况下准确地识别了故障变量。

在第二个案例中, 线性系统在第 101 个样本处从模式 3 切换到模式 2。从第 201 个样本开始, 在 x 上添加 1.8

的偏差故障。从图 4 可以容易地观察到 PCA 混合模型未能检测到故障。此外，我们观察到基于 LCDL 的方法的故障检测性能与 FGMM 相当。从图 5 可以看出，BIGMC 索引图表明传感器测量值 x_1 、 x_2 和 x_3 都异常。然而，事实并非如此。因此，过程人员无法识别故障的真实原因。值得注意的是，T 和 SPE 贡献图是使用最后 200 个故障数据获得的，假设它正确检测到了故障。然而，根据图 4，PCA 混合模型未能检测到故障。与前一种情况一样，稀疏贡献图正确地找出了故障变量 x_1 。值得注意的是，稀疏性是相对于传统故障诊断方法的一个有前途的优势。稀疏性使过程人员能够集中于异常的主要原因。基于上述观察，所提方法在 Case 2 中是最好的。

在 Case 3 中，我们的目标是测试多个变量同时发生故障的情况。在这种情况下， x_1 和 x_2 同时受到偏差故障的污染。从图 6 可以看出，PCA 混合模型、FGMM 和基于 LCDL 的方法都成功检测到了故障。从图 7 可以看出，T 贡献图未能隔离两个故障变量。SPE 贡献图和 BIGMC 索引图都表明 x_1 和 x_2 严重故障。从稀疏贡献图中，我们可以观察到 x_1 和 x_2 都异常，并且由于贡献图的稀疏性，其他正常变量的贡献为零，这有助于定位主要故障变量。值得注意的是，稀疏贡献图直接反映了故障的大小，因为变量 3 的稀疏贡献大于变量 4。

3.2 CSTH 过程

在本节中，将基于标签一致性字典学习（LCDL）的多模态过程监测方法应用于连续搅拌槽加热器（CSTH）过程。CSTH 过程是一个具有过程、仪表和执行器非线性特性的现实平台，已被广泛用于比较不同的过程监测方法。该过程模型具有质量和热量平衡。其配置图如图 8 所示。可以看出，冷水（CW）和热水（HW）在罐中混合，然后由蒸汽加热。此外，CSTH 过程在多个闭环下运行，因此液位、流量和温度测量值保持在其期望设定点。存在两种标准操作模式，模式 1 和模式 2。两种模式的设定值如表 3 所示，其中所有值的单位为 mA。CSTH 过程的更详细描述可以在文献（Thornhill et al. [2008]）中找到。

首先，我们从每种操作模式收集 2000 个样本作为训练数据集。对于 PCA 混合模型，在模型构建阶段保留 2 个主成分。字典通过标签一致性字典学习算法获得。所有三种方法的控制限都在 98% 置信水平下获得。为了验证所提方法的有效性和优越性，提供了表 4 中的两种场景。

在 Case 1 中，CSTH 过程最初在模式 1 运行 100 个样本，然后切换到模式 2。从第 201 个样本开始，-0.3 的偏差故障污染了流量传感器。图 9 展示了三种不同方法的监测结果，包括 PCA 混合模型、FGMM 和基于 LCDL 的方法。由于故障幅值较小， nT 和 $nSPE$ 都遭受了大量的漏报，这可以从图 9(a) 和 (b) 中容易地观察到。从图 9(c) 可以看出，FGMM 的监测性能优于 PCA 混合模型，但它并非不受从第 324 个样本到第 335 个样本的漏报影响。与其对应方法相比，基于 LCDL 的方法将故障检测率提高到 95%，比 FGMM 高 6.5%。详细的监测结果可以在表 5 中找到。

在流量传感器故障被成功检测到之后，利用所提的稀疏贡献图（SpCP）执行故障诊断。此外，传统的贡献图和 BIGMC 也用于此场景以进行比较。从图 10(a) 和 (b) 可以看出，传统贡献图未能识别故障的可能原因。更具体地说，T 贡献图表明液位具有最大贡献，因此选择了错误的变量液位作为故障最可能的原因。SPE 贡献图表明流量和温度是主要的故障变量。相比之下，BIGMC 索引成功隔离了故障操作的正确原因。从图 10(d) 可以看出，SpCP 能够隔离正确的变量，并且所有变量的贡献都是稀疏的。SpCP 的这一特性对于操作人员在没有混淆的情况下识别故障的真实变量非常有帮助。

在第二个案例中，当冷水温度升高时，罐中的温度偏离其设定点并趋于偏高。从表 5 可以看出，所提方法具有最高的故障检测率。一旦检测到故障，操作人员想要找出故障的原因，从而执行故障诊断。与前一种情况一样，传统的贡献图、BIGMC 和 SpCP 被用于进行比较。从图 12 可以看出，SpCP 成功隔离了主要的故障变量。

4. 结论

提出了一种新的基于 LCDL 的多模态过程监测方法和基于 SpCP 的故障诊断方法。它们在故障检测率和隔离故障变量的能力方面展示了相对于传统方法的优越性。此外，这是首次在稀疏表示框架内提出一种不需要历史故障数据的故障诊断方法，通过扩充学习到的字典来实现。

参考文献

[1] Alcalá, C. and Qin, S. Reconstruction-based contribution for process monitoring. Automatica, 45, 1593–1600, 2009.

- [2] Aharon, M., Elad M. and Bruckstein A. K-SVD: an algorithm for designing overcomplete dictionaries for sparse representation. *IEEE Transactions On Image Processing*, 54, 4311–4322, 2006.
- [3] Cheng, C., Hsu, C. and Chen, M. Adaptive Kernel Principal Component Analysis (KPCA) for monitoring small disturbances of nonlinear processes. *Ind. Eng. Chem. Res.*, 49, 2254–2262, 2010.
- [4] Chen, J. and Liu, J. Mixture principal component analysis models for process monitoring. *Ind. Eng. Chem. Res.*, 38, 1478–1488, 1999.
- [5] Elad, M. and Aharon, M. Image denoising via sparse and redundant representations over learned dictionaries. *IEEE Transactions On Image Processing*, 15, 3736–3745, 2006.
- [6] Elad, M., Figueiredo, M. and Ma, Y. On the Role of sparse and redundant representations in image processing. *Proceedings of the IEEE*, 98, 972–982, 2010.
- [7] Elad, M. Sparse and redundant representations: from theory to applications in signal and image processing. Springer Science and Business Media, 2010.
- [8] Eldar, Y. and Kutyniok, G. (Eds.). Compressed sensing: theory and applications. Cambridge University Press, 2012.
- [9] Ge, Z. and Song, Z. Process monitoring based on independent component analysis–principal component analysis (ICA-PCA) and similarity factors. *Ind. Eng. Chem. Res.*, 46, 2054–2063, 2007.
- [10] Ge, Z., Song, Z. and Gao, F. Review of Recent Research on Data-Based Process Monitoring. *Ind. Eng. Chem. Res.*, 52, 3543–3562, 2013.
- [11] Ge, Z.; Song, Z. Mixture Bayesian Regularization Method of PPCA for Multimode Process Monitoring. *AIChE J.*, 56, 2838–2849, 2010.
- [12] Ge, Z.; Song, Z. Multimode process monitoring based on Bayesian method. *J. Chemometrics*, 23, 636–650, 2009.
- [13] Hwang, D. and Han, C. Real-time monitoring for a process with multiple operating modes. *Contr. Eng. Pr.*, 7, 891–902, 1999.
- [14] Jiang, Z., Lin, Z., and Davis, L. Label consistent K-SVD: learning a discriminative dictionary for recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 35, 2651–2664, 2013.
- [15] Kano, M., Nagao, K., Hasebe, S., Hashimoto, I. and Ohno, H. Statistical process monitoring based on dissimilarity of process data. *AIChE J.*, 48, 1231–1240, 2002.
- [16] MacGregor, J., and Kourti, T. Statistical Process Control of Multivariable Processes. *Contr. Eng. Pr.*, 3(3), 403–414, 1995.
- [17] Miller, P., Swanson, R. and Heckler, C. Contribution plots: a missing link in multivariate quality control. *Applied Mathematics and Computer Science*, 8, 775–792, 1998.
- [18] Ning, C., Chen, M. and Zhou, D. Hidden Markov Model-Based Statistics Pattern Analysis for Multimode Process Monitoring: An Index-Switching Scheme. *Ind. Eng. Chem. Res.*, 53, 11084–11095, 2014.
- [19] Qin, S. Statistical process monitoring: Basics and beyond. *Journal of Chemometrics*, 17, 480–502, 2003.
- [20] Raich, A. and Cinar, A. Statistical process monitoring and disturbance diagnosis in multivariate continuous processes. *AIChE J.*, 42, 995–1009, 1996.
- [21] Ren, L. and Lv, W. Fault detection via sparse representation for semiconductor manufacturing processes. *IEEE Transactions on Semiconductor Manufacturing*, 27, 252–259, 2014.
- [22] Singhal, A. and Seborg, D. Pattern matching in multivariate time series databases using a moving-window approach. *Ind. Eng. Chem. Res.*, 41, 3822–3838, 2002.
- [23] Tong, H. and Crowe, C. Detection of Gross Errors in Data Reconciliation by Principal Component Analysis. *AIChE J.*, 41, 1712–1722, 1995.
- [24] Thornhill, N., Patwardhan, S. and Shah, S. A continuous stirred tank heater simulation model with applications. *J. Process Control*, 18, 347–360, 2008.
- [25] Wise, B. and Gallagher, N. The process chemometrics approach to process monitoring and fault detection. *J. Process Control*, 6, 329–348, 1996.
- [26] Wright, J., Ma, Y., Mairal, J., Sapiro, G., Huang, T. and Yan, S. Sparse representation for computer vision and pattern recognition. *Proceedings of the IEEE*, 98, 1031–1044, 2010.
- [27] Wright, J., Yang, A., Ganesh, A., Sastry, S. and Ma, Y. Robust face recognition via sparse representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 31, 210–227, 2009.
- [28] Wang D. and Kong S. A classification-oriented dictionary learning model: explicitly learning the particularity and commonality across categories. *Pattern Recognition*, 47, 885–898, 2014.
- [29] Wu, L., Chen, X., Peng, Y., Ye, Q. and Jiao, J. Fault detection and diagnosis based on sparse representation classification (SRC). *Proceedings of the 2012 IEEE International Conference on Robotics and Biomimetics*, 926–931,

2012.

- [30] Xu, X., Xie, L. and Wang, S. Multi-mode process monitoring method based on PCA mixture model. CIESC J., 62, 743–752, 2011.
- [31] Yoon, S. and MacGregor, J. Fault diagnosis with multivariate statistical models, part I: Using steady state fault signatures. J. Process Control, 11, 387–400, 2001.
- [32] Yu, J. and Qin, S. Multimode process monitoring with Bayesian inference-based finite Gaussian mixture models. AIChE J., 54, 1811–1829, 2008.
- [33] Yu, J. A new fault diagnosis method of multimode processes using Bayesian inference based Gaussian mixture contribution decomposition. Engineering Applications of Artificial Intelligence., 26, 456–466, 2013.
- [34] Yan, J., Tian, C., Huang, J. and Albertao, F. Incremental dictionary learning for fault detection with applications to oil pipeline leakage detection. Electronics Letters, 47, 1198–1199, 2011.
- [35] Zhou, D., Li, G. and Qin, S. Total projection to latent structures for process monitoring. AIChE J., 56, 168–178, 2010.
- [36] Zhao, S., Zhang, J. and Xu, Y. Monitoring of processes with multiple operating modes through multiple principle component analysis models. Ind. Eng. Chem. Res., 43, 7025–7035, 2004.
- [37] Zhao, S., Zhang, J. and Xu, Y. Performance monitoring of processes with multiple operating modes through multiple PLS models. J. Process Control, 16, 763–772, 2006.